

Universitat Autònoma de Barcelona
Grau en Matemàtica Computacional i Analítica de Dades

Predicció espaciotemporal de la posició dels jugadors i la pilota en futbol

Treball de Fi de Grau

Autor: Eloi Mercader Morillas

NIU: 1666675

Tutor: Oriol Ramos Terrades

curs 2025-2026

Abstract

Abstract

Català

Aquest treball estudia la predicció espai-temporal del moviment dels jugadors i de la pilota en futbol mitjançant xarxes neuronals sobre grafs. S'utilitzen dades de seguiment a deu fotogrames per segon de deu partits de l'A-League australiana, procedents del conjunt obert de SkillCorner. L'objectiu és analitzar com es poden representar les interaccions entre els agents del joc per anticipar trajectòries futures i, alhora, incorporar progressivament més context tàctic al model.

La primera aproximació adapta al futbol una xarxa convolucional espai-temporal sobre grafs concebuda originalment per a la predicció de trànsit. A partir de cinc segons d'observació, el model prediu conjuntament les posicions dels vint-i-dos jugadors i de la pilota durant els tres segons següents. Es compara un graf estàtic global amb un graf dinàmic i signat que s'adapta a cada seqüència, diferencia companys i adversaris, i incorpora característiques de moviment i de posició relativa respecte de la pilota. Els resultats mostren que adaptar la topologia del graf a cada jugada millora la representació de les interaccions i la precisió de les trajectòries predites.

La segona aproximació reformula el problema com una predicció de transicions entre fases tàctiques amb horitzó variable. Les anotacions de possessió, opcions de passada, desmarcatges i duels, juntament amb la proximitat i el control de l'espai, es representen mitjançant un graf relacional. Sobre aquest graf, un codificador compartit combina convolucions relacionals sobre grafs amb un transformador temporal, i alimenta diverses capçaleres especialitzades per predir la fase següent, les pauses llargues, els canvis de possessió i les trajectòries fins a l'inici de la propera fase. Aquesta formulació permet adaptar l'horitzó de predicció a l'estructura del joc i aprendre una representació latent amb contingut tàctic, com mostra l'organització de l'espai latent i l'avaluació qualitativa de les trajectòries.

Anglès

This thesis studies the spatio-temporal prediction of player and ball movement in football using graph neural networks. It uses tracking data sampled at ten frames per second from ten Australian A-League matches in the open SkillCorner dataset. The goal is to analyse how interactions between the agents in the game can be represented in order to anticipate future trajectories while progressively incorporating richer tactical context into the model.

The first approach adapts a spatio-temporal graph convolutional network, originally designed for traffic forecasting, to football tracking data. Given five seconds of observations, the model jointly predicts the positions of the twenty-two players and the ball over the following three seconds. A global static graph is compared with a signed dynamic graph that adapts to each sequence, distinguishes teammates from opponents, and incorporates movement features and relative position with respect to the ball. The results show that adapting the graph topology to each play improves the representation of interactions and the accuracy of the predicted trajectories.

The second approach reformulates the task as the prediction of transitions between tactical phases with a variable horizon. Possession, passing-option, off-ball-run, and engagement annotations, together with proximity and spatial control information, are represented through a relational graph. On top of this graph, a shared encoder combines relational graph convolutions with a temporal Transformer and feeds several specialised heads that predict the next phase, long stoppages, possession changes, and trajectories until the beginning of the following phase. This formulation adapts the prediction horizon to the structure of the game and learns a latent representation with tactical content, as shown by the organisation of the latent space and the qualitative evaluation of the trajectories.

Índex

1	Introducció	3
1.1	Objectius i abast	3
2	Fonaments teòrics	5
2.1	Revisió bibliogràfica	5
2.2	Estructura de grafs	5
2.3	Polinomis de Chebyshev i aproximació	7
2.4	Xarxa convolucional espai-temporal sobre grafs per a la predicció de trànsit . . .	8
3	Origen del conjunt de dades i elements	9
4	Metodologia	10
4.1	Model 1: STGCN	10
4.2	Model amb graf relacional per la predicció de transicions tàctiques amb horitzó variable	15
5	Resultats i avaluació	28
5.1	Configuració experimental i mètriques d'avaluació	28
5.2	Primera aproximació: predicció de trajectòries amb horitzó fix	30
5.3	Segona aproximació: representació tàctica i predicció amb horitzó variable	32
6	Discussió	36
7	Conclusions	37
A	Preprocessament de les dades per STGCN	39
A.1	Normalització	40
A.2	Partició de dades	41
B	Preprocessament de les dades pel model amb graf relacional: la fase com a unitat de mostra	41
B.1	Construcció i mostreig per fases	41
B.2	Selecció de l'instant de predicció i augmentació estocàstica	42
C	Visualitzacions complementàries dels procediments	43
C.1	Control d'espai: Voronoi versus regió dominant	44
C.2	Estructura de les relacions tàctiques del graf multi-relacional	44
C.3	Corbes d'aprenentatge	45
C.4	Exemples qualitatius de predicció de trajectòries	46
D	Repositori del codi	47

1 Introducció

El futbol és un esport dinàmic en què vint-i-dos jugadors i una pilota evolucionen simultàniament dins d'un espai compartit. El moviment de cada jugador no depèn únicament de la seva velocitat o de la direcció que segueix en un instant determinat, sinó també de la posició dels companys, dels adversaris, de la pilota i del context tàctic de la jugada. Per tant, una trajectòria no es pot interpretar de manera aïllada: forma part d'un sistema de múltiples agents en què les accions dels diferents participants estan relacionades.

Aquesta naturalesa col·lectiva fa que la predicció de moviment en futbol sigui un problema especialment complex. Dues situacions aparentment semblants des del punt de vista geomètric poden evolucionar de manera diferent segons quin equip tingui la possessió, quins espais estiguin disponibles, quins jugadors participin directament en l'acció o quin sigui l'objectiu tàctic de la fase de joc. Així, la predicció no consisteix només a extrapolar posicions, sinó a representar una dinàmica en què espai, temps i interaccions s'influencien mútuament.

Les dades de seguiment, denominades *tracking data* en anglès, permeten reconstruir la posició dels jugadors i de la pilota al llarg del partit amb una freqüència elevada. Aquest treball utilitza el conjunt de dades obert de SkillCorner, format per deu partits de l'A-League australiana i obtingut a partir del vídeo d'emissió [9]. Aquest tipus de dades fa possible estudiar el moviment com una seqüència espaciotemporal contínua, però també introdueix dificultats pràctiques: les identitats observades poden variar, alguns fotogrames contenen informació incompleta i la pilota no sempre és visible. Per aquest motiu, la preparació del conjunt de dades és una part essencial del problema.

Les xarxes neuronals sobre grafs ofereixen una representació adequada per a aquest escenari. Els jugadors i la pilota es poden associar als nodes d'un graf, mentre que les arestes permeten expressar proximitat, pertinença a un mateix equip o relacions pròpies del desenvolupament de la jugada. D'aquesta manera, el model no rep únicament una llista de coordenades, sinó una descripció estructurada de les entitats i de les dependències que hi ha entre elles.

1.1 Objectius i abast

L'objectiu general del treball és desenvolupar i analitzar models neuronals sobre grafs capaços de predir l'evolució espaciotemporal dels jugadors i de la pilota a partir de dades de seguiment de futbol. Es pretén estudiar de manera progressiva quina informació necessita aquesta predicció: primer, la geometria i el moviment recent; després, l'estructura d'equips i, finalment, les relacions semàntiques i les fases que organitzen el desenvolupament del joc.

Per assolir aquest objectiu general, el treball planteja els objectius específics següents:

1. Preparar les dades de seguiment i les anotacions dels partits per obtenir seqüències consistents i representar els jugadors i la pilota mitjançant grafs.
2. Adaptar al futbol una xarxa convolucional sobre grafs espai-temporals concebuda originalment per a la predicció de trànsit [12], i comparar una representació estàtica de les interaccions amb un graf dinàmic i signat adaptat a cada seqüència.
3. Reformular la predicció a partir de les fases tàctiques del partit, enteses com intervals en què el joc manté una categoria general d'acció, i construir un graf relacional que incorpori informació geomètrica, control espaciotemporal i diferents tipus d'interacció entre els jugadors.
4. Desenvolupar i avaluar un codificador espaciotemporal per predir la transició a la fase tàctica següent i les trajectòries de durada variable que hi condueixen.

Des del punt de vista metodològic, el treball avança en dues etapes complementàries. La primera parteix d'una arquitectura consolidada en un domini amb grafs estàtics i n'estudia l'adaptació

a un entorn en què les interaccions varien contínuament. La comparació entre el graf estàtic i el graf dinàmic signat permet analitzar de manera controlada l'efecte de representar la geometria concreta de cada jugada i la distinció entre companys i adversaris.

La segona etapa situa la transició entre fases al centre del problema i incorpora les anotacions de possessió, opcions de passada, desmarcatges i duels com a relacions diferenciades dins del graf. El codificador s'entrena aleshores mitjançant diverses tasques relacionades, de manera que la representació interna no s'especialitzi únicament a reduir l'error de les coordenades, sinó que també conservi informació sobre la dinàmica i l'estructura tàctica de la fase observada.

El treball no planteja aquests models com a alternatives independents, sinó com dues aproximacions successives a una mateixa pregunta: quina representació permet anticipar millor el moviment futur dels participants d'un partit de futbol?

2 Fonaments teòrics

Abans de descriure la metodologia desenvolupada, és necessari establir els conceptes teòrics sobre els quals es construeixen els models del treball. Aquesta secció presenta les nocions bàsiques que permeten representar les interaccions entre jugadors mitjançant grafs i processar-ne la dinàmica espaciotemporal

2.1 Revisió bibliogràfica

La predicció de trajectòries de múltiples agents s’ha estudiat en àmbits com la navegació de vianants i la conducció autònoma. Aquests problemes comparteixen una idea fonamental amb el futbol: el moviment futur d’una entitat no depèn únicament del seu historial, sinó també de la posició i el comportament dels agents que l’envolten.

La xarxa convolucional espai-temporal sobre grafs proposada per Yu, Yin i Zhu segueix una línia complementària. En lloc de tractar agents mòbils, representa una xarxa viària com un graf i combina convolucions espacials i temporals per predir l’evolució del trànsit [12]. La regularitat de la seva arquitectura i la separació explícita entre tractament espacial i temporal la converteixen en un punt de partida adequat per estudiar-ne la transferència al futbol. Aquesta transferència, però, no és directa: en una xarxa viària els nodes i les connexions són estables, mentre que en un partit els nodes es desplacen i la rellevància de cada interacció canvia amb la jugada.

En canvi, en els esports d’equip, les dades de seguiment permeten representar de manera contínua el moviment col·lectiu. FootBots aplica una arquitectura basada en transformadors a la predicció conjunta de trajectòries en futbol [3]. Des d’una perspectiva més tàctica, TacticAI representa situacions de córner mitjançant aprenentatge geomètric sobre grafs per predir resultats de la jugada i proposar ajustos en la disposició dels jugadors [11].

Aquests treballs mostren que la predicció en futbol es beneficia tant de l’evolució temporal de les trajectòries com de l’estructura col·lectiva del joc. Tanmateix, les interaccions són canviants, els dos equips assumeixen funcions diferents i una mateixa configuració espacial pot tenir significats distints segons la possessió o la fase. Aquestes particularitats justifiquen que el present treball estudiï primer un graf dinàmic i signat i, posteriorment, una representació relacional vinculada a les transicions tàctiques.

2.2 Estructura de grafs

Un graf és una estructura matemàtica que permet representar un conjunt d’entitats i les relacions existents entre elles. Formalment, un graf es defineix com

$$\mathcal{G} = (\mathcal{V}, \mathcal{E}),$$

on $\mathcal{V} = \{v_1, \dots, v_N\}$ és el conjunt de nodes o vèrtexs, i $\mathcal{E} \subseteq \mathcal{V} \times \mathcal{V}$ és el conjunt d’arestes que connecten parelles de nodes. En el context d’aquest treball, els nodes poden representar jugadors, punts temporals o entitats espacials, mentre que les arestes codifiquen relacions d’interacció, proximitat o dependència entre ells.

La connectivitat del graf es pot representar mitjançant una matriu d’adjacència

$$W \in \mathbb{R}^{N \times N},$$

on cada element W_{ij} indica la intensitat de la relació entre els nodes v_i i v_j . En el cas d’un graf no ponderat, $W_{ij} = 1$ si existeix una arista entre v_i i v_j , i $W_{ij} = 0$ en cas contrari. En un graf ponderat, en canvi, W_{ij} pot prendre valors reals que representen el pes o la força de la connexió. Si el graf és no dirigit, la matriu d’adjacència és simètrica, és a dir, $W_{ij} = W_{ji}$.

A partir de la matriu d’adjacència es defineix la matriu de grau:

$$D = \text{diag}(d_1, \dots, d_N),$$

on

$$d_i = \sum_{j=1}^N W_{ij}$$

és el grau del node v_i , és a dir, la suma dels pesos de les arestes incidents sobre aquest node.

Un senyal sobre un graf és una funció que assigna un valor, o un vector de característiques, a cada node del graf. En el cas escalar, aquest senyal es pot representar com un vector

$$x \in \mathbb{R}^N,$$

on x_i és el valor associat al node v_i . De manera més general, si cada node té F característiques, el senyal es representa com una matriu

$$X \in \mathbb{R}^{N \times F}.$$

En dominis regulars com les imatges o les sèries temporals, la convolució es defineix a partir d'una noció de veïnatge ordenat. En canvi, en un graf arbitrari no existeix, en general, una ordenació regular dels nodes ni una estructura euclidiana subjacent. Per aquest motiu, la definició de convolució sobre grafs requereix una formulació diferent.

Una manera d'abordar aquest problema és interpretar la convolució com una operació que combina la informació d'un node amb la dels seus veïns segons l'estructura del graf. Aquesta idea dona lloc a formulacions espacials de la convolució sobre grafs. Una alternativa més formal, basada en la teoria espectral de grafs, consisteix a definir la convolució en el domini freqüencial del graf mitjançant els autovectors del seu laplacà. Aquesta és la perspectiva que es presenta a continuació.

En un domini estructurat com una graella (imatges, sèries temporals), la convolució és una operació ben definida. En canvi, sobre un graf arbitrari $\mathcal{G} = (\mathcal{V}, \mathcal{E})$ amb N nodes, la convolució no té una definició directa en el domini espacial. La teoria espectral de grafs proporciona una alternativa: definir la convolució en el domini freqüencial mitjançant la descomposició del laplacà del graf.

Donat un graf amb matriu d'adjacència $W \in \mathbb{R}^{N \times N}$ i matriu de grau

$$D = \text{diag} \left(\sum_j W_{ij} \right),$$

el laplacà normalitzat es defineix com:

$$L = I_N - D^{-1/2} W D^{-1/2}. \quad (1)$$

El laplacà L és simètric i semidefinit positiu, i admet una descomposició en autovalors:

$$L = U \Lambda U^T, \quad (2)$$

on U és la matriu d'autovectors i

$$\Lambda = \text{diag}(\lambda_0, \dots, \lambda_{N-1}).$$

La transformada de Fourier sobre el graf d'un senyal $x \in \mathbb{R}^N$ es defineix com $\hat{x} = U^T x$, i la convolució espectral amb un filtre g_θ s'expressa com:

$$g_\theta * x = U g_\theta(\Lambda) U^T x, \quad (3)$$

on

$$g_\theta(\Lambda) = \text{diag}(\theta_0, \dots, \theta_{N-1})$$

és el filtre en el domini freqüencial.

2.3 Polinomis de Chebyshev i aproximació

Els polinomis de Chebyshev són una família de polinomis $T_0, T_1, T_2, \dots$ ordenats per grau (el polinomi T_k té grau k) que s'utilitzen habitualment com a base per aproximar funcions sobre l'interval $[-1, 1]$. La idea és que qualsevol funció regular sobre aquest interval es pot escriure de manera aproximada com una combinació lineal d'un nombre finit dels primers polinomis de la família, $f(x) \approx \sum_{k=0}^{K-1} \theta_k T_k(x)$, i com més termes inclou la combinació, millor és l'aproximació. La família es defineix de manera recursiva, és a dir, cada polinomi es construeix a partir dels dos anteriors mitjançant una relació senzilla:

$$T_0(x) = 1, \quad T_1(x) = x, \quad T_k(x) = 2x T_{k-1}(x) - T_{k-2}(x).$$

Aplicant la recurrència obtenim, per exemple, $T_2(x) = 2x^2 - 1$ i $T_3(x) = 4x^3 - 3x$. Tots els polinomis estan acotats per $|T_k(x)| \leq 1$ sobre el rang $[-1, 1]$, propietat que garanteix l'estabilitat numèrica.

Tot i que la definició original és sobre una variable real, la mateixa recurrència té sentit quan se substitueix la variable x per una matriu quadrada $A \in \mathbb{R}^{N \times N}$. Els polinomis de Chebyshev, per tant, avaluats sobre una matriu son noves matrius obtingudes amb les operacions definides prèviament on la constant 1 es reemplaça per la identitat I_N . La recurrència esdevé, doncs,

$$T_0(A) = I_N, \quad T_1(A) = A, \quad T_k(A) = 2A T_{k-1}(A) - T_{k-2}(A),$$

on $T_k(A)$ és una matriu de la mateixa mida que A . Perquè el desenvolupament tingui bon comportament, és a dir, que les magnituds dels successius $T_k(A)$ no creixin sense control, els autovalors d' A han de caure al rang $[-1, 1]$. Aquesta condició és la que motiva l'escalament del laplacà per mitjà de l'expressió:

$$\tilde{L} = (2/\lambda_{\max}) L - I_N \quad (4)$$

El càlcul de la descomposició en autovalors completa (3) té un cost $O(N^3)$ i el filtre resultant no és espacialment localitzat. Per resoldre ambdós problemes, Hammond et al. (2011)[6] proposen aproximar el filtre mitjançant polinomis de Chebyshev de primer tipus fins a ordre $K_s - 1$:

$$g_\theta(\Lambda) \approx \sum_{k=0}^{K_s-1} \theta_k T_k(\tilde{\Lambda}), \quad (5)$$

on

$$\tilde{\Lambda} = \frac{2}{\lambda_{\max}} \Lambda - I_N$$

escala els autovalors al rang $[-1, 1]$, i els polinomis de Chebyshev es calculen recursivament:

$$T_0(\tilde{\Lambda}) = I_N, \quad T_1(\tilde{\Lambda}) = \tilde{\Lambda}, \quad T_k(\tilde{\Lambda}) = 2\tilde{\Lambda} T_{k-1}(\tilde{\Lambda}) - T_{k-2}(\tilde{\Lambda}).$$

Substituint (5) a (3) obtenim

$$g_\theta * x \approx \sum_{k=0}^{K_s-1} \theta_k U T_k(\tilde{\Lambda}) U^\top x. \quad (6)$$

Per poder calcular aquesta expressió sense disposar dels autovectors U , ens cal substituir cada terme $U T_k(\tilde{\Lambda}) U^\top$ per un polinomi avaluat sobre una matriu coneguda. Per fer-ho, emprem la definició del laplacà escalat definida a (4).

Com que es tracta d'una transformació afí de L i, per tant, conserva els mateixos autovectors U i té com a diagonal $\tilde{\Lambda}$, aleshores:

$$\tilde{L} = U \tilde{\Lambda} U^\top. \quad (7)$$

D'acord amb (7), obtenim:

$$U T_k(\tilde{\Lambda}) U^\top = T_k(U \tilde{\Lambda} U^\top) = T_k(\tilde{L}),$$

i substituint a (6), la convolució sobre el graf es pot expressar com:

$$g_\theta * x \approx \sum_{k=0}^{K_s-1} \theta_k T_k(\tilde{L}) x \quad (8)$$

Aquesta formulació té dos avantatges fonamentals: (1) la complexitat es redueix a $O(K_s \cdot |\mathcal{E}|)$, i (2) el filtre és K_s -localitzat, és a dir, cada node agrega informació únicament dels seus veïns fins a distància $K_s - 1$ salts en el graf.

2.4 Xarxa convolucional espai-temporal sobre grafs per a la predicció de trànsit

L'arquitectura *Spatio-Temporal Graph Convolutional Network*, proposada per Yu, Yin i Zhu [12], combina convolucions temporals causals amb convolucions espectrals sobre grafs per capturar dependències espacials i temporals. Per simplicitat, d'ara endavant es farà servir l'abreviació anglesa STGCN per referir-s'hi.

El caràcter causal de les convolucions temporals implica que la representació d'un instant només depèn d'aquest instant i dels anteriors. Això impedeix que durant el processament de la seqüència s'utilitzi informació temporal futura que no estaria disponible en una predicció real.

L'arquitectura s'organitza en blocs de convolució espai-temporal, denominats ST-Conv, que segueixen una disposició temporal-espacial-temporal:

$$\text{ST-Conv}(x) = \Gamma_1 * \text{ReLU}(\Theta * (\Gamma_0 * x)),$$

on Γ_0 i Γ_1 són convolucions temporals amb una unitat lineal amb porta (*Gated Linear Unit*, GLU), i Θ representa la convolució espectral sobre el graf.

La unitat lineal amb porta és un mecanisme que regula quina part de la informació produïda per la convolució temporal es transmet a la capa següent. Per aplicar-la, la sortida de la convolució es divideix, al llarg de la dimensió dels canals, en dos tensors de la mateixa mida, P i Q :

$$\text{GLU}(P, Q) = P \odot \sigma(Q),$$

on σ és la funció sigmoide i $\odot$ denota el producte element a element. El tensor P conté la informació candidata, mentre que $\sigma(Q) \in [0, 1]$ actua com una porta que n'atenua o en permet el pas per a cada canal i instant temporal. D'aquesta manera, la xarxa pot seleccionar quins patrons temporals conserva abans i després de la propagació espacial.

En el context del trànsit, el graf representa la xarxa viària, és a dir, els nodes són sensors de velocitat i les arestes reflecteixen connexions físiques entre carreteres. Aquesta topologia és estàtica per naturalesa i, per tant, l'estructura de la xarxa no canvia amb el temps.

3 Origen del conjunt de dades i elements

Les dades emprades en aquest treball formen part del conjunt de dades públic *SkillCorner Open Data*[9], concretament 10 partits de la A-League australiana corresponents a la temporada 2024–2025. SkillCorner deriva les dades de seguiment a partir de la retransmissió en directe del partit mitjançant models de visió per computador. Per tant, no requereix sensors als jugadors ni instrumentació específica a l'estadi, fet que redueix el cost d'adquisició de les dades. Tanmateix, aquest tipus de senyal pot presentar discontinuïtats que cal gestionar durant el preprocessament. Cada partit es distribueix com un directori que conté tres fitxers amb la mateixa arrel numèrica:

- `{match_id}_tracking_extrapolated.jsonl`: un registre per fotograma del partit, amb la posició de la pilota i de tots els jugadors detectats. La identificació numèrica de jugadors és estable al llarg de tot el partit, fet que utilitzarem per fixar l'ordre dels nodes del graf.
- `{match_id}_dynamic_events.csv`: una taula d'esdeveniments puntuals etiquetats al partit (passades potencials, desmarcades sense pilota, duels, possessions), cadascun acotat per un parell (`frame_start`, `frame_end`).
- `{match_id}_phases_of_play.csv`: el partit segmentat en fases tàctiques i els seus respectius (`frame_start`, `frame_end`).

Els fitxers `{match_id}_phases_of_play.csv` contenen les fases tàctiques que convé definir per la seva rellevància en apartats posteriors del treball:

- **build_up**: La pilota es troba al terç defensiu de l'equip en possessió. El portador està sota pressió o bé l'equip rival manté la seva línia de jugadors en una posició molt avançada.
- **create**: Fase per defecte, habitualment associada al terç central del camp. També pot aparèixer al terç defensiu si el portador no rep pressió, o al terç atacant si la línia defensiva rival no està situada a prop de la seva pròpia àrea.
- **finish**: La pilota es troba al terç atacant o al terç central, la línia defensiva rival està situada a prop de la seva àrea i la possessió s'ha mantingut durant almenys un segon.
- **direct**: Fase que comença amb una passada llarga en l'eix longitudinal i que no correspon a un canvi de joc, efectuada des de la pròpia meitat del terreny de joc del passador.
- **chaotic**: Possessió disputada i de curta durada. Una fase evita aquesta etiqueta si inclou almenys tres passades o bé si la possessió es manté durant almenys cinc segons. Els rebutjos dels defensors també es classifiquen com a fases caòtiques.
- **transition**: Fase que comença quan l'equip recupera la possessió a la pròpia meitat i progressa ràpidament cap a la meitat rival.
- **quick_break**: Fase que comença quan l'equip recupera la possessió a la meitat del rival i progressa ràpidament pel camp.
- **set_play**: Inclou córners, faltes i sacades de banda llargues dirigides cap a l'àrea. La fase finalitza quan el rival estableix una possessió clara o quan la pilota és refusada.
- **stoppage**: Classe específica del sistema que indica que entre la fase actual i la fase següent transcorre un temps superior al llindar definit per a una pausa llarga. Aquesta classe agrupa situacions en què la continuïtat del joc queda interrompuda, com ara aturades per lesió, revisions del videoarbitratge, pèrdues de temps o altres interrupcions prolongades. Aquestes situacions no es consideren informatives per a l'aprenentatge de la trajectòria, ja que les posicions posteriors dels jugadors poden deixar de dependre de la dinàmica observada.

4 Metodologia

La metodologia segueix una progressió incremental. Primer s'estudia una formulació geomètrica amb horitzó fix, que permet adaptar el model STGCN i analitzar l'efecte de construir el graf de manera estàtica o dinàmica. Les limitacions d'aquest plantejament motiven després una ampliació basada en fases, relacions tàctiques i trajectòries de durada variable. Totes dues formulacions parteixen dels mateixos partits i comparteixen la representació dels vint-i-dos jugadors i la pilota, però responen a nivells diferents de contextualització del joc.

4.1 Model 1: STGCN

Un cop realitzat el preprocessament de les dades detallat a l'Annex A i preparades les seqüències d'entrada, es presenta la primera adaptació del model STGCN. Aquesta variant utilitza una única relació espacial fixa, comuna a totes les mostres del conjunt de dades.




Figura 1: Arquitectura del model *STGCN*.

El model consta de dos blocs spatiotemporal (blocs *ST-Conv*) seguits d'una capa de sortida completament connectada. Cada bloc *ST-Conv* conté dues capes de convolució temporal amb mecanisme de porta i una capa de convolució espacial sobre grafs situada al mig.

Anomenarem K_t a la mida del kernel de la convolució temporal 1D que cada bloc *ST-Conv* aplica sobre l'eix dels fotogrames, i fixa quants fotogrames consecutius es combinen a cada operació temporal. Adoptem $K_t = 3$.

A deu fotogrames per segon, $K_t = 3$ cobreix una finestra de 0.3 segons, un horitzó suficient per registrar canvis de direcció curts.

Cada bloc *ST-Conv* redueix la dimensió temporal en $2(K_t - 1) = 4$ fotogrames (amb $K_t = 3$).

Després dels dos blocs *ST-Conv*, la representació interna té la forma

$$H^{(2)} \in \mathbb{R}^{B \times 42 \times N \times 128},$$

on els 42 fotogrames restants ja no contenen únicament les coordenades d'entrada, sinó característiques espai-temporals apreses pel model. Abans de predir les posicions futures cal resumir aquest eix temporal en una representació única per a cada node. Per fer-ho, la capa de sortida aplica una darrera convolució temporal amb un nucli de mida 42. Com que el nucli cobreix tota la dimensió temporal disponible, la longitud de la seqüència es redueix a un sol element:

$$H^{(2)} \in \mathbb{R}^{B \times 42 \times N \times 128} \mapsto U \in \mathbb{R}^{B \times 1 \times N \times 128}.$$

La convolució manté el mateix mecanisme de porta que les convolucions temporals dels blocs anteriors. La seva sortida es divideix en dues parts P i Q , que es combinen com

$$U = P \odot \sigma(Q) + R,$$

on R és la connexió residual corresponent a l'últim instant de la representació d'entrada. D'aquesta manera, la sortida combina una síntesi apresada dels 42 fotogrames amb un camí directe des de l'estat temporal més recent. Aquesta connexió és útil perquè, en predicció de trajectòries, la posició futura depèn fortament de l'estat final observat, mentre que la convolució sobre tota la finestra aporta informació sobre la dinàmica que ha conduït fins a aquest estat.

Un cop eliminada la dimensió temporal unitària, cada node queda representat per un vector

$$u_{b,n} \in \mathbb{R}^{128}.$$

Sobre aquest vector s'aplica una mateixa transformació lineal per a tots els nodes:

$$o_{b,n} = W_{\text{out}} u_{b,n} + b_{\text{out}}, \quad W_{\text{out}} \in \mathbb{R}^{60 \times 128}, \quad o_{b,n} \in \mathbb{R}^{60}.$$

Els 60 valors obtinguts corresponen a les dues coordenades dels 30 fotogrames futurs. Per tant, el vector es reorganitza segons

$$o_{b,n} \mapsto [\hat{p}_{b,1,n}, \hat{p}_{b,2,n}, \dots, \hat{p}_{b,30,n}], \quad \hat{p}_{b,k,n} \in \mathbb{R}^2,$$

i, després d'ordenar les dimensions, la sortida completa del model és

$$\hat{Y} \in \mathbb{R}^{B \times 30 \times 23 \times 2}.$$

Els 30 fotogrames futurs es prediuen conjuntament en una única passada del model. Per tant, no se segueix un esquema autoregressiu en què la posició predita en un instant es torna a introduir com a entrada per obtenir la següent. Aquesta decisió evita que els errors dels primers fotogrames es propaguin i s'acumulin al llarg de l'horitzó de tres segons, i permet calcular tota la trajectòria en paral·lel. Cal destacar que els diferents horitzons no es tracten com a problemes completament independents, és a dir totes les coordenades futures es deriven de la mateixa representació espai-temporal de 128 canals.

4.1.1 STGCN estàtic

A partir del conjunt d'entrenament desnormalitzat, calculem la matriu de distàncies euclidianes mitjanes entre cada parell de nodes:

$$\bar{d}_{ij} = \frac{1}{T_{\text{train}}} \sum_{t=1}^{T_{\text{train}}} \|p_i^{(t)} - p_j^{(t)}\|_2,$$

on $p_n^{(t)} \in \mathbb{R}^2$ és la posició desnormalitzada en metres del node n al frame t i T_{train} és el nombre de seqüències vàlides del conjunt d'entrenament, especificat a 6. Empíricament, $\bar{d}_{ij}$ pren valors fora de la diagonal entre aproximadament 5 metres (parelles de defenses centrals i laterals del mateix equip que tendeixen a estar a prop) i 55 (un porter contra una davanter contrari).

La transformació de distàncies a pesos segueix el patró clàssic del laplacià espectral: un kernel gaussià aplicat element a element, simetritzat:

$$W_{ij} = \exp\left(-\frac{\bar{d}_{ij}^2}{\sigma^2}\right), \quad W_{ii} = 0, \quad W \leftarrow \frac{1}{2}(W + W^\top).$$

La diagonal s'anul·la deliberadament: el missatge propi de cada node es propaga en l'expansió de Chebyshev, no a través de W .

El model STGCN original, Yu et al., 2018[12] defineix σ^2 com la *variancia* de les distàncies entre sensors. Aquesta tria funciona bé en xarxes viàries perquè les distàncies entre sensors són

intrínsecament heterogènies (sensors adjacents a pocs metres, sensors entre ciutats a centenars de quilòmetres): una variancia gran genera pesos prou repartits.

En el cas del futbol, en canvi, les distàncies entre jugadors estan confinades per la geometria del camp i per la configuració tàctica: estadísticament,

$$\text{var}(\bar{d}_{ij}) \ll \mathbb{E}[\bar{d}_{ij}]^2.$$

Concretament, amb el nostre conjunt d'entrenament obtenim $\mathbb{E}[\bar{d}_{ij}] \approx 25.5 \text{ m}$ i $\text{std}(\bar{d}_{ij}) \approx 14 \text{ m}$. Si seguissim la prescripció original tindriem $\sigma^2 \approx 196 \text{ m}^2$ i, per a la parella mitjana,

$$\frac{\bar{d}_{ij}^2}{\sigma^2} \approx \frac{25,5^2}{14^2} \approx 3,3 \quad \implies \quad W_{ij} \approx e^{-3,3} \approx 0,037.$$

És a dir, el pes típic seria $\sim 4\%$ del seu màxim possible. El graf colapsaria a una topologia gairebé nul·la. La solució adoptada és la següent:

$$\sigma = \frac{1}{N(N-1)} \sum_{i \neq j} \bar{d}_{ij} \approx 25.5 \text{ m},$$

és a dir, σ és la mitjana de les distàncies fora de la diagonal, no la seva desviació. Així, per construcció, la parella mitjana satisfà $\bar{d}_{ij}^2/\sigma^2 \approx 1$ i, per tant, $W_{ij} \approx e^{-1} \approx 0,368$.

Empíricament, aplicant el kernel gaussià amb σ proposat:

$$\min_{i \neq j} W_{ij} \approx 0,113, \quad \max_{i \neq j} W_{ij} \approx 0,590, \quad \overline{W_{ij}} \approx 0,373,$$

exactament coherent amb e^{-1} a la franja central.

Per tant, podem concloure que el graf queda dens i ben condicionat.




Figura 2: Distància mitjana entre nodes i matriu d'adjacència després d'aplicar el kernel gaussià

Una observació qualitativa que convé remarcar: tot i que la matriu d'adjacència W ha estat construïda sense cap senyal d'equip, el mapa de calor de la matriu mostra una estructura en blocs: les parelles de jugadors del mateix equip tenen pesos sistemàticament més alts que les parelles inter-equips. És una conseqüència de l'organització tàctica del futbol: dos defenses centrals estaran propers entre ells més sovint que un defensor central i un davanter contrari. Aquesta estructura emergent suggereix que el graf estàtic ja captura implícitament una part de la informació d'equip.

Com que la matriu d'adjacència W és global i no varia ni entre partits ni entre èpoques, tota la transformació espectral es realitza una sola vegada en una fase de preprocessament i es desa a disc.

El procediment es divideix en les següents etapes:

(i) Laplacà normalitzat escalat:

$$L = I - D^{-\frac{1}{2}} W D^{-\frac{1}{2}}, \quad \tilde{L} = \frac{2}{\lambda_{\max}} L - I.$$

L'autovalor màxim $\lambda_{\max}$ s'obté amb `scipy.sparse.linalg.eigsh` en mode 'LM' amb $k = 1$, que retorna només l'autovalor extrem.

(ii) Tria del radi del filtre espacial K_s : K_s és l'ordre dels polinomis de Chebyshev de la convolució espectral sobre el graf i, en aquesta arquitectura, fixa fins a quants salts en el graf pot agregar informació cada node. Adoptem $K_s = 3$.

Amb aquest valor, cada node agrega informació dels seus veïns fins a $K_s - 1 = 2$ salts. Sobre el graf estàtic completament connectat, 2 salts ja cobreixen tots els nodes amb pes no negligible, es a dir, el filtre té camp receptiu efectiu global.

(iii) Polinomis de Chebyshev: A partir de $\tilde{L}$ es construeix la base $T_k(\tilde{L})$ via la recurrència

$$T_0 = I, \quad T_1 = \tilde{L}, \quad T_k = 2\tilde{L}T_{k-1} - T_{k-2},$$

fins a ordre $K_s - 1$ i s'apilen horitzontalment:

$$L_k = [T_0 \mid T_1 \mid \cdots \mid T_{K_s-1}] \in \mathbb{R}^{N \times K_s N}.$$

Amb $K_s = 3$ i $N = 23$, $L_k \in \mathbb{R}^{23 \times 69}$. Aquest tensor es desa i s'utilitza com a base fixa no entrenable a totes les convolucions espectrals del model.

4.1.2 STGCN dinàmic

La principal limitació del model estàtic és que el graf és global i fix per a totes les seqüències, per tant, la matriu d'adjacència reflecteix les distàncies mitjanes de tot l'entrenament, no les relacions espacials reals en cada instant. A més, no distingeix entre companys d'equip i rivals. En el model dinàmic, la matriu d'adjacència es calcula per a cada seqüència del batch a partir de les posicions mitjanes dels $N_{\text{HIS}} = 50$ fotogrames d'entrada:

$$\bar{p}_n^{(b)} = \frac{1}{N_{\text{HIS}}} \sum_{t=1}^{N_{\text{HIS}}} p_n^{(b,t)} \quad \text{per a cada mostra } b \text{ i node } n,$$

$$d_{ij}^{(b)} = \left\| \bar{p}_i^{(b)} - \bar{p}_j^{(b)} \right\|_2$$

El criteri d'escalat és el mateix que en el cas estàtic però calculat localment:

$$\sigma_b = \frac{1}{N(N-1)} \sum_{i \neq j} d_{ij}^{(b)}, \quad W_{ij}^{(b)} = s_{ij} \cdot \exp\left(-\frac{(d_{ij}^{(b)})^2}{\sigma_b^2}\right),$$

on $s_{ij} \in \{-1, +1\}$ és l'element de la matriu de signes que codifica la relació d'equip. Més concretament, la matriu de signes

$$S \in \{-1, +1\}^{N \times N}$$

s'assigna de la manera següent:

$$s_{ij} = \begin{cases} +1, & \text{si } \text{equip}(i) = \text{equip}(j), \\ -1, & \text{si } \text{equip}(i) \neq \text{equip}(j), \\ +1, & \text{si } i = 22 \text{ o } j = 22 \text{ (pilota)}. \end{cases}$$

Aquesta formulació captura la natura dual de les interaccions en futbol: les relacions entre companys són cooperatives (moviments coordinats, cobertures) i les relacions entre rivals són antagòniques (pressió, marcatge). La pilota es connecta positivament a tots els nodes, ja que el seu moviment influeix en tots els jugadors independentment de l'equip.

Per al laplaciana d'un graf signat, la matriu de grau es defineix amb valors absoluts:

$$D_{ii} = \sum_j |W_{ij}|.$$

En el model estàtic, el laplaciana L no canvia, per tant n'hi ha prou amb calcular $\lambda_{\max}$ una sola vegada en una fase de preprocessament i emmagatzemar-lo al disc, juntament amb els polinomis de Chebyshev.

En el model dinàmic, en canvi, el laplaciana $L^{(b)}$ depèn de la matriu de signes i de la matriu de distàncies entre nodes, que varia per cada mostra del batch. Cal recalcular $\lambda_{\max}^{(b)}$ a cada pas, durant l'entrenament i sobre la GPU on resideixen els tensors.

La solució adoptada és `torch.linalg.eigvalsh`, una rutina de PyTorch que aprofita la simetria del laplaciana per calcular tots els seus autovalors reals en una única crida i que és vectoritzable per lots. Donat un tensor $L \in \mathbb{R}^{B \times N \times N}$, retorna $\Lambda \in \mathbb{R}^{B \times N}$ amb els autovalors ordenats per cada mostra; l'autovalor màxim s'obté simplement com

$$\lambda_{\max}^{(b)} = \max_i \text{eigvalsh}(L^{(b)})_i, \quad b = 1, \dots, B.$$

A més del graf dinàmic, el model 2 augmenta les features d'entrada de cada node amb informació dinàmica:

Feature	Descripció	Càlcul
x, y	Posició normalitzada	Dades directes
v_x, v_y	Velocitat	$v^{(t)} = p^{(t)} - p^{(t-1)}$
$\Delta x_{\text{ball}}, \Delta y_{\text{ball}}$	Posició relativa a la pilota	$p^{(t)} - p_{\text{ball}}^{(t)}$
$\Delta v_{x,\text{ball}}, \Delta v_{y,\text{ball}}$	Velocitat relativa a la pilota	$v^{(t)} - v_{\text{ball}}^{(t)}$

La velocitat (v_x, v_y) pot ser negativa, indicant el sentit del moviment en cada eix. No es divideix pel temps entre fotogrames ($\Delta t = 0.1$ s) perquè, sent constant, equival a un factor d'escala que la xarxa absorbeix automàticament als pesos de la primera capa.

La posició relativa respecte de la pilota, $(\Delta x_{\text{ball}}, \Delta y_{\text{ball}})$, permet relacionar directament cada jugador amb l'element central de la jugada. D'aquesta manera, el model disposa des del primer nivell de la xarxa d'informació sobre la distància i l'orientació del jugador respecte de la pilota. Sense aquesta característica, aquesta relació s'hauria d'inferir de manera indirecta a través dels missatges propagats pel graf, cosa que podria requerir diversos salts entre nodes.

La velocitat relativa respecte de la pilota, $(\Delta v_{x,\text{ball}}, \Delta v_{y,\text{ball}})$, complementa aquesta informació incorporant la dinàmica del moviment. Mentre que la posició relativa indica on es troba el jugador en relació amb la pilota, la velocitat relativa permet descriure com evoluciona aquesta relació, és a dir, si el jugador s'hi aproxima, se n'allunya o es desplaça lateralment respecte d'ella.

Finalment, per tots dos models STGCN, la funció de pèrdua és comuna i correspon a l'error quadràtic mitjà sobre les coordenades normalitzades:

$$\mathcal{L}_{\text{MSE}} = \frac{1}{B \cdot T_{\text{pred}} \cdot N \cdot 2} \sum_{b,t,n,c} (\hat{y}_{b,t,n,c} - y_{b,t,n,c})^2.$$

En aquesta expressió, B és la mida del lot, T_{pred} és el nombre d'instants futurs predits, N és el nombre de nodes i el factor 2 correspon a les dues coordenades espacials. Els tensors $\hat{y}_{b,t,n,c}$ i $y_{b,t,n,c}$ representen, respectivament, la posició predita i la posició real del node n a l'instant futur t per a la coordenada c .

4.2 Model amb graf relacional per la predicció de transicions tàctiques amb horitzó variable

Els dos models anteriors permeten estudiar la predicció de trajectòries a partir de la geometria i del moviment recent dels jugadors i de la pilota. Els seus resultats quantitatius i qualitatius es presenten posteriorment a 5.2. Tanmateix, amb independència del rendiment obtingut, tots dos comparteixen limitacions derivades de la mateixa formulació del problema. Aquest apartat les exposa perquè constitueixen la motivació metodològica de l'ampliació desenvolupada a continuació.

La primera limitació és la manca de context semàntic. El model STGCN pot aprendre regularitats espacials i temporals complexes, però les seves entrades descriuen principalment on es troben les entitats i com s'han mogut recentment. Fins i tot en la variant dinàmica, que diferencia companys i adversaris i incorpora posicions i velocitats relatives a la pilota, el model no rep informació explícita sobre l'acció que s'està produint ni sobre la intenció tàctica que la condiciona.

En el model estàtic, les arestes es deriven de les distàncies mitjanes globals del conjunt d'entrenament; en el model dinàmic, es recalculen a partir de les distàncies mitjanes de cada seqüència i se signen segons la pertinença a un mateix equip o a equips contraris. La segona formulació és més informativa, però la proximitat continua sent el criteri principal per determinar la intensitat de les interaccions. En conseqüència, el graf no pot expressar que dos jugadors relativament allunyats estan connectats per una opció de passada, ni distingir aquesta relació d'un desmarcatge o d'una disputa per la pilota. En termes tàctics, una relació explícita entre dos participants de l'acció pot ser més rellevant que la proximitat entre altres jugadors que no hi intervenen directament.

La tercera limitació prové de l'horitzó temporal fix. Predir sempre els tres segons posteriors proporciona una tasca homogènia i facilita la comparació entre mostres, però aquest interval no coincideix necessàriament amb els límits significatius del joc. Una finestra pot acabar abans que es resolgui una acció, travessar una transició entre dues situacions tàctiques o cobrir un període en què no es produeix cap canvi rellevant. Per tant, dues prediccions amb la mateixa longitud poden correspondre a processos futbolístics de naturalesa i durada molt diferents. Una segmentació basada en fases tàctiques permet substituir aquest límit arbitrari per unitats temporals definides per l'evolució mateixa del partit.

Aquestes limitacions orienten la segona aproximació del treball. L'objectiu és incorporar relacions tàctiques diferenciades, representar el partit com una successió de fases i adaptar la longitud de la trajectòria predita a la transició que es vol anticipar. Alhora, el model s'entrena mitjançant diverses tasques relacionades per obtenir una representació compartida que integri la geometria recent amb informació sobre l'estructura i la continuïtat del joc.

4.2.1 La fase com a unitat tàctica i assumpcions

La primera aproximació divideix el partit en finestres temporals homogènies, però aquestes finestres no coincideixen necessàriament amb les unitats tàctiques que estructurin el joc. En aquesta segona aproximació, una fase es considera un interval durant el qual l'equip en possessió genera un escenari relativament homogeni que condiciona el posicionament i el comportament de tots dos equips.

La representació espai-temporal del partit es pot expressar, per tant, com la composició de

les representacions de les seves fases:

$$\mathcal{P} = \bigcup_{k=1}^K \mathcal{F}_k,$$

on $\mathcal{F}_k$ conté l'evolució de les posicions i les interaccions dels jugadors i de la pilota dins d'un mateix context tàctic, i K és el nombre total de fases. Aquesta divisió permet substituir l'horitzó fix de la primera part per un horitzó determinat per l'inici de la fase següent.

La formulació del problema i el disseny de l'arquitectura es basen en les assumpcions següents:

1. El moviment de cada agent presenta dependències espacials i temporals: està condicionat tant per la disposició de la resta de nodes com per l'evolució recent del joc.
2. Les interaccions rellevants no es redueixen a la proximitat. Les opcions de passada, els desmarcatges, els duels i la possessió aporten relacions tàctiques diferenciades.
3. Durant una mateixa fase de joc, les relacions tàctiques i espai-temporals tendeixen a mantenir-se relativament estables. Això permet considerar cada fase com un interval temporal amb una estructura interna coherent. Aquesta assumpció es reflectirà, per exemple, en el fet que determinades característiques associades als jugadors, com ara la seva posició, romandran constants durant el transcurs de cada fase.
4. El desenvolupament d'una fase depèn tant del seu estat present com de la fase que la precedeix. Les transicions tàctiques no són independents, sinó que es troben condicionades pel context immediat anterior del partit.
5. En el futbol, els períodes d'absència de joc actiu com interrupcions, pauses o situacions sense desenvolupament tàctic rellevant són recurrents i també formen part de la dinàmica del partit. Per tant, aquestes situacions es consideren igualment una fase de joc dins de la representació global del sistema.

4.2.2 Plantejament multitasca i arquitectura general




Figura 3: Arquitectura del model multi-head. L'encoder espai-temporal g_θ comprimeix la finestra d'observació $\mathcal{B}_t$ en un vector global $\mathbf{h} \in \mathbb{R}^D$. L'*EventHead* produeix els logits de la classificació de fase c , que es transformen en un embedding $\mathbf{e}_{\text{event}}$ via l'*EventEmbedding*. Aquest embedding es concatena amb $\mathbf{h}$ per formar el vector condicionat $\mathbf{h}_{\text{cond}}$, que alimenta les tres *heads* restants: *PauseHead* (probabilitat de pausa llarga), *PossessionChangeHead* (probabilitat de canvi de possessió) i *TrajectoryHead* (trajectòria S dels nodes fins a l'inici de la propera fase).

El sistema rep com a entrada una finestra d'observació $\mathcal{W}_t$ que cobreix una porció de l'evolució recent del partit i ha d'inferir, des de l'instant de predicció t , què succeirà en la transició cap a la propera fase tàctica. Concretament, es modelen quatre prediccions acoblades:

1. El tipus $c \in \{1, \dots, 9\}$ de la propera fase de joc.
2. La probabilitat $p \in [0, 1]$ que la transició impliqui una pausa llarga, on una pausa llarga es defineix com $\Delta t_{\text{proper}} > 30$ s.
3. La probabilitat $q \in [0, 1]$ que entre la fase actual i la propera hi hagi canvi de possessió.
4. La trajectòria $S \in \mathbb{R}^{K_t \times N \times 2}$ dels N nodes del joc des de l'instant t fins a l'inici de la fase següent, on K_t depèn de la durada de cada transició.

Les quatre prediccions anteriors comparteixen una característica estructural: depenen totes del mateix estat observable del partit a l'instant t , però són de natures molt diferents; una classificació categòrica, dues binàries i una regressió espacial i cadascuna requereix una capa de sortida pròpia.

Aquesta arquitectura que consisteix en compartir el cos del model entre tasques i especialitzar només els mòduls finals és el que s'anomena *multi-head*¹.

En el cas particular en el que es treballarà, cal definir un *encoder*² espai-temporal, és a dir capaç de capturar tant la relació espacial com temporal, per obtenir una representació compacta de la seqüència d'entrada.

Formalment, denotant per $\mathcal{B}_t$ la representació estructurada de la finestra $\mathcal{W}_t$, l'encoder defineix l'aplicació:

$$g_\theta : \mathcal{B}_t \rightarrow \mathbf{h} \in \mathbb{R}^D$$

Per tant, comprimeix tota la informació observable de la finestra en un únic vector global $\mathbf{h}$ de dimensió D , perquè, a posteriori, una cascada de quatre heads especialitzades operi sobre aquesta representació per produir cadascuna de les quatre prediccions.

Aleshores, el model defineix l'aplicació:

$$f_\theta : \mathcal{B}_t \mapsto (c, p, q, S).$$

4.2.3 Graf multi-relacional dinàmic

A diferència de la formulació STGCN, on les arestes del graf es deriven exclusivament de la distància entre nodes, el model multi-head incorpora relacions de naturalesa diversa: algunes provenen de l'anotació tàctica del partit i altres es deriven geomètricament. D'aquí neix la necessitat de representar la finestra com un graf multi-relacional:

$$\mathcal{G}_\tau = \left(\mathcal{V}, \{\mathcal{E}_\tau^{(r)}\}_{r=1}^R \right), \quad \tau \in \mathcal{W}_t,$$

on $\mathcal{V}$ és el conjunt fix de $N = 23$ nodes i $\mathcal{E}_\tau^{(r)}$ és el subconjunt d'arestes del tipus r actives al frame τ , per a $R = 5$ tipus de relació en total. Cadascun d'aquests tipus es processarà amb un conjunt propi de pesos a la capa R-GCN, de manera que el model pot aprendre patrons d'agregació diferents per a cada mena d'interacció.

Les cinc relacions implementades, ordenades pel seu origen, són:

¹El terme *multi-head* fa referència al patró arquitectural d'un encoder compartit seguit de múltiples mòduls de sortida especialitzats (les *heads*), cadascun assignat a una predicció diferent. Conservem la denominació anglesa per coherència amb la literatura del camp, on no ha cristallitzat una traducció catalana estable.

²En el context de l'aprenentatge profund, un *encoder* és un mòdul d'una xarxa neuronal encarregat de transformar les dades d'entrada en una representació interna vectorial, coneguda habitualment com a *embedding*. Aquesta representació busca concentrar la informació més rellevant de l'entrada en un espai de característiques adequat per al processament posterior.

r	Etiqueta	Origen	Direccionalitat	Tipus de pes
1	passing_option	dynamic_events.csv	dirigida	binari
2	off_ball_run	dynamic_events.csv	dirigida	binari
3	on_ball_engagement	dynamic_events.csv	simètrica	binari
4	player_possession	dynamic_events.csv	simètrica	binari
5	spatial_proximity	derivada geomètricament	simètrica	continu

Les quatre primeres provenen de l'anotació de SkillCorner[9] i codifiquen, respectivament: la connexió entre el posseïdor de la pilota i els potencials receptors d'una passada ($r = 1$); el desplaçament d'un jugador sense pilota cap al posseïdor o cap a un espai obert ($r = 2$); el duel entre un defensor i el posseïdor en un contacte proper amb la pilota ($r = 3$); i la possessió efectiva de la pilota per part d'un jugador en un instant donat ($r = 4$). Aquestes quatre relacions són temporals i a cada frame només n'hi ha unes poques d'actives. A més, porten un pes binari, ja que reflecteixen esdeveniments etiquetats com a presents o absents.

La cinquena relació, **spatial_proximity**, es deriva en temps d'execució a partir de les coordenades dels nodes al frame i , a diferència de les quatre primeres, està sempre activa amb un pes continu per a cada parell de nodes. Aporta la informació purament geomètrica que el model STGCN ja explotava i complementa el senyal tàctic de les altres quatre.

Cadascun dels esdeveniments (arestes) anotats al fitxer **dynamic_events.csv** té un rang de fotogrames d'activitat [**frame_start**, **frame_end**]. Per a un frame mostrejat τ , una aresta del tipus $r \in \{1, 2, 3, 4\}$ entre dos nodes és activa si i només si existeix un esdeveniment d'aquell tipus que involucri els dos nodes amb:

$$\text{frame_start} \leq \tau \leq \text{frame_end}.$$

Aquest filtre es resol per parell de nodes i per frame en una passada sobre el conjunt de dades. A l'Annex C.2 es recull un exemple de visualització de com evolucionen algunes de les relacions esmentades amb el pas del temps.

La cinquena relació es construeix per cada frame mostrejat a partir de les coordenades $\mathbf{x}_i^\tau$ dels nodes com un kernel gaussià sobre la distància euclidiana:

$$\mathbf{A}_\tau^{(5)}[i, j] = \exp \left(-\frac{\|\mathbf{x}_i^\tau - \mathbf{x}_j^\tau\|_2^2}{2\sigma_{\text{prox}}^2} \right) \mathbb{I}_{\{i \neq j\}}$$

Aquesta forma és la mateixa que la de la formulació STGCN.

Les cinc matrius d'adjacència tenen la diagonal anul·lada deliberadament: cap relació transporta el missatge d'un node cap a si mateix. En lloc d'això, el missatge propi de cada node es propaga mitjançant una matriu de pesos dedicada W_{self} , separada de les matrius $W^{(r)}$ associades a les relacions. Aquesta separació, seguint la formulació original de Schlichtkrull et al. (2018), permet al model aprendre de manera independent amb quina força cada node reté la seva pròpia representació i com integra els missatges dels veïns. Si les auto-connexions anessin a la diagonal, aquesta decisió quedaria distribuïda arbitràriament entre les R matrius relacionals i la separació conceptual es perdria.

4.2.4 Representació de l'entrada

Després de construir la finestra seguint els procediments especificats a l'Annex B, cada mostra retorna els tensors següents:

Tensor	Forma	Significat
<code>node_numeric</code>	$T_{\max} \times N \times 9$	característiques numèriques per node
<code>position_idx</code>	N	posició tàctica categòrica
<code>context</code>	$T_{\max} \times 18$	informació global del fotograma
<code>adj_per_relation</code>	$R \times T_{\max} \times N \times N$	graf multi-relacional
<code>frame_mask</code>	$T_{\max}$	fotogrames vàlids

Durant l'entrenament, s'afegeix una dimensió de lot B . Per exemple, `node_numeric` passa de

$$T_{\max} \times N \times 9$$

a

$$B \times T_{\max} \times N \times 9.$$

Per cada fotograma t i node n , el tensor `node_numeric` conté nou canals:

$$x_{t,n}^{\text{node}} = [x, y, v_x, v_y, \Delta x_b, \Delta y_b, \mathbb{K}_{\text{ball}}, \text{equip}, A].$$

Si $p_{t,n} = (x_{t,n}, y_{t,n})$ és la posició del node i $p_{t,b}$ la posició de la pilota, la velocitat i la posició relativa es calculen com

$$v_{t,n} = \frac{p_{t,n} - p_{t-s,n}}{s/10}, \quad r_{t,n} = p_{t,n} - p_{t,b}.$$

El canal $\mathbb{K}_{\text{ball}}$ distingeix la pilota dels jugadors, i el canal `equip` diferencia si el node pertany a l'equip local o al visitant.

Els canals anteriors descriuen cada node de manera local: la seva posició, el seu moviment i la seva relació amb la pilota. Tanmateix, no contempla que dos jugadors amb la mateixa posició i la mateixa velocitat poden controlar quantitats d'espai molt diferents segons la disposició de la resta d'agents. Per exemple, un jugador situat en camp obert pot disposar d'una regió de control molt més gran que un altre completament envoltat de rivals. Aquesta magnitud difícilment pot ser recuperada de manera directa per una xarxa de pas de missatges limitada a l'agregació de veïnatges locals. El canal A codifica explícitament aquesta propietat.

La idea de dividir un espai en regions associades al punt més proper té el seu origen en els diagrames de Voronoi, introduïts formalment per Georgy Voronoy a principis del segle XX [10]. En aquest tipus de partició, cada generador defineix una cel·la formada pels punts de l'espai que li són més propers que a qualsevol altre generador. En el context d'aquest treball, els generadors són els jugadors i les cel·les resultants s'interpreten com una aproximació de la regió del camp que cadascun d'ells domina en un instant determinat.

Sigui $\mathcal{C} = [-\frac{L}{2}, \frac{L}{2}] \times [-\frac{W}{2}, \frac{W}{2}]$ el terreny de joc, amb $L = 105$ m i $W = 68$ m. Modelem el control mitjançant la regió dominant³ de cada jugador, definida com la porció del camp que pot assolir abans que cap altre. Per obtenir-la cal definir un model del temps d'arribada $T_n(z)$ del jugador n a un punt z del camp. En aquest treball s'adopta un model senzill en dues fases:

1. durant un temps de reacció t_r , el jugador no pot canviar de direcció i continua amb la seva velocitat actual $v_{t,n}$, fins a la posició efectiva $\tilde{p}_{t,n} = p_{t,n} + t_r v_{t,n}$;
2. a partir d'aquí, esprinta en línia recta cap a z a una velocitat màxima $v_{\max}$ comuna per tots els jugadors.

³El control d'espai (*pitch control*) i la noció de regió dominant provenen de Taki i Hasegawa (2000) i de la seva formulació probabilística posterior (Spearman, 2017; Fernández i Bornn, 2018).

El temps d'arribada és, doncs,

$$T_n(z) = t_r + \frac{\|z - \tilde{p}_{t,n}\|_2}{v_{\max}}, \quad t_r = 0,7 \text{ s},$$

i l'ocupant d'un punt z és el primer jugador a arribar-hi, definit per la funció:

$$\omega_t(z) = \arg \min_n T_n(z).$$

Ara bé, si t_r i $v_{\max}$ són comuns a tots els jugadors, t_r és una constant additiva i $v_{\max}$ una constant multiplicativa positiva, totes dues independents de n . Per tant, minimitzar $T_n(z)$ equival a minimitzar simplement la distància a la posició efectiva:

$$\omega_t(z) = \arg \min_n T_n(z) = \arg \min_n \|z - \tilde{p}_{t,n}\|_2.$$

Així, el control d'espai es redueix a una tessellació de Voronoi sobre les posicions efectives $\tilde{p}_{t,n}$, és a dir, sobre les posicions dels jugadors desplaçades segons la seva inèrcia de moviment. Aquesta formulació fa que la velocitat modifiqui la regió de control de cada jugador: un jugador que es desplaça cap endavant tendeix a dominar més espai en la direcció del seu moviment i menys al darrere. D'aquesta manera, el control d'espai no depèn només de la posició instantània, sinó també de la dinàmica recent del jugador.

La regió dominant del jugador n és el conjunt de punts que controla,

$$R_{t,n} = \{z \in \mathcal{C} : \omega_t(z) = n\},$$

i el canal A n'és la fracció del camp que ocupa,

$$A_{t,n} = \frac{|R_{t,n}|}{|\mathcal{C}|} \in [0, 1], \quad \sum_n A_{t,n} = 1,$$

on $|\cdot|$ denota l'àrea. A la pràctica, $\mathcal{C}$ es discretitza en una graella regular de cel·les d'1 m² (105 × 68 = 7140 cel·les), i cada cel·la s'assigna al jugador amb la posició efectiva més propera. L'àrea d'una regió s'obté simplement com el recompte de les seves cel·les. Aquesta discretització converteix les integrals d'àrea en recomptes. La pilota no actua com a generadora de la tessellació i, per tant, rep àrea zero. A l'Annex C.1 es pot veure un exemple de representació del control d'espai per equip.

Per altra banda, el tensor `position_idx` assigna a cada ranura una categoria tàctica. El vocabulari utilitzat conté 19 rols de jugador i dues categories especials: una per a la pilota i una altra per a rols desconeguts. En total, doncs, hi ha 21 categories.

Aquest índex no s'utilitza com un enter ordinari. Es projecta a un espai vectorial de dimensió 8:

$$\rho_n \in \{1, \dots, 21\} \quad \mapsto \quad e_n^{\text{pos}} \in \mathbb{R}^8.$$

Això permet que el model aprengui semblances entre rols sense imposar una distància artificial entre identificadors. Per exemple, dos laterals poden aprendre representacions properes, mentre que la pilota i un porter poden quedar en regions molt diferents de l'espai latent.

A més de la posició tàctica de cada jugador, la representació incorpora informació compartida per tots els nodes d'un mateix fotograma. El tensor `context` té 18 canals i segueix l'estructura:

$$c_t = \left[\begin{array}{cccccc|ccccccc} m_t & p & a & q & \tau & u & e_1 & e_2 & \cdots & e_9 & h_1 & h_2 & h_3 \end{array} \right],$$

on:

- m_t és el temps de partit normalitzat per una durada de referència de dues hores;

- p identifica el període, codificat com 0 per la primera part i 1 per la segona;
- a indica si l'equip en possessió ataca d'esquerra a dreta;
- q indica si l'equip local té la possessió;
- τ és el temps transcorregut des de l'inici de la fase de referència, escalat amb una referència de 30 s;
- u indica si el fotograma pertany a la fase actual;
- $e_1, \dots, e_9$ són la codificació d'una sola classe activa del tipus de fase;
- h_1, h_2, h_3 són el control de l'equip local a cadascun dels tres terços del camp.

La fase de referència depèn del fotograma. Si el fotograma pertany a la fase actual, s'utilitzen els atributs de la fase actual i $u = 1$. Si pertany a la fase prèvia, s'utilitzen els atributs de la fase prèvia i $u = 0$.

A partir de la mateixa tessel·lació definida anteriorment, es deriva un descriptor global del fotograma que resumeix com es reparteix el control del camp entre els dos equips al llarg de la seva longitud. Per fer-ho, es parteix de la mateixa graella $\mathcal{G}$ i s'agrupen les cel·les en tres terços segons la seva coordenada longitudinal:

$$\mathcal{G}_j = \{z \in \mathcal{G} : z_x \in I_j\}, \quad I_1 = \left[-\frac{L}{2}, -\frac{L}{6}\right), \quad I_2 = \left[-\frac{L}{6}, \frac{L}{6}\right), \quad I_3 = \left[\frac{L}{6}, \frac{L}{2}\right].$$

Aquí, z_x representa la coordenada longitudinal de la cel·la z , i cada interval I_j defineix un dels tres terços del camp. D'aquesta manera, $\mathcal{G}_j$ conté totes les cel·les de la graella que pertanyen al terç j .

Per a cada terç, es pren com a característica la fracció de cel·les controlades per l'equip local:

$$h_{t,j} = \frac{1}{|\mathcal{G}_j|} \sum_{z \in \mathcal{G}_j} \mathbb{K}\{\text{equip}(\omega_t(z)) = \text{local}\}, \quad j = 1, 2, 3,$$

on $\omega_t(z)$ és l'ocupant del punt z , és a dir, el jugador que hi arriba abans segons la tessel·lació definida anteriorment, i $\text{equip}(\cdot)$ n'indica l'equip. La funció indicadora val 1 si la cel·la està controlada per un jugador de l'equip local i 0 en cas contrari. Per tant, la suma compta el nombre de cel·les del terç j controlades pel local, i la divisió per $|\mathcal{G}_j|$ transforma aquest recompte en una fracció.

Els tres valors $[h_{t,1}, h_{t,2}, h_{t,3}]$ pertanyen a l'interval $[0, 1]$ i descriuen el perfil territorial del control: indiquen en quines zones del camp domina més l'equip local i, de manera complementària, on domina més l'equip visitant.

Finalment, **frame_mask** es tracta d'un vector booleà de longitud T_{max} que indica els fotogrames amb dades vàlides. Per a cada fotograma mostrejat k , es defineix una màscara de validesa:

$$m_k = \begin{cases} 1, & \text{si el fotograma és vàlid,} \\ 0, & \text{si no hi ha dades o és farciment.} \end{cases}$$

En la implementació aquesta màscara té dues funcions: impedeix que el transformador atengui a posicions artificials i permet recuperar l'últim fotograma vàlid, que és l'instant de predicció real utilitzat per la capçalera de trajectòria.

4.2.5 Codificador espai-temporal

El codificador rep el batch $\mathcal{B}_t$ i en produeix un únic vector global $\mathbf{h} \in \mathbb{R}^D$ que comprimeix tota la informació observable de la finestra. Aquest vector és l'entrada de la cascada de heads especialitzades. El codificador rep tres fonts d'informació de naturalesa diferent per a cada finestra del lot $b \in \{1, \dots, B\}$:

- Les característiques numèriques de node, $x_{b,t,n}^{\text{node}} \in \mathbb{R}^9$, definides per a cada fotograma t i cada node n definides a 4.2.4.
- El vector del rol tàctic, $e_{b,n}^{\text{pos}} \in \mathbb{R}^{d_{\text{pos}}}$ amb $d_{\text{pos}} = 8$. S'obté tal com s'explica a 4.2.4 i és invariant en el temps, d'acord amb l'assumpció 3 de 4.2.1.
- El context global del fotograma, $c_{b,t} \in \mathbb{R}^{18}$ que es detalla a 4.2.4. És invariant entre nodes.

Per a cada tripleta (b, t, n) (lot, fotograma i node), aquestes tres fonts es combinen en un sol vector mitjançant una concatenació:

$$\tilde{H}_{b,t,n}^{(0)} = \left[x_{b,t,n}^{\text{node}} \parallel e_{b,n}^{\text{pos}} \parallel c_{b,t} \right] \in \mathbb{R}^{d_{\text{in}}}, \quad d_{\text{in}} = 9 + d_{\text{pos}} + 18 = 35.$$

Com que la posició d'un jugador e^{pos} no depèn de t i el context c no depèn de n , els seus valors es propaguen al llarg de l'eix corresponent per a cada tripleta (b, t, n) . Aquesta replicació és la que permet alinear les tres fonts en un únic vector $\tilde{H}_{b,t,n}^{(0)}$ ben definit per a cada parell node-fotograma.

Sobre aquest vector concatenat s'aplica una transformació lineal comuna a totes les tripletes (b, t, n) :

$$H_{b,t,n}^{(0)} = W_{\text{proj}} \tilde{H}_{b,t,n}^{(0)}, \quad W_{\text{proj}} \in \mathbb{R}^{D \times d_{\text{in}}},$$

amb $D = 128$. El resultat,

$$H^{(0)} \in \mathbb{R}^{B \times T \times N \times D},$$

és la representació inicial sobre la qual operen totes les capes posteriors del codificador.

La seva funció principal és projectar les característiques comunes de cada tripleta (b, t, n) , a un espai de dimensió superior per tal de poder capturar relacions complexes.

Cada bloc del codificador comença amb una xarxa convolucional sobre grafs relacionals, abreujada R-GCN. Per a cada relació r , la matriu d'adjacència es normalitza simètricament:

$$\hat{A}_t^{(r)} = \left(D_t^{(r)} \right)^{-1/2} A_t^{(r)} \left(D_t^{(r)} \right)^{-1/2}, \quad D_t^{(r)}[i, i] = \sum_j A_t^{(r)}[i, j].$$

Aquesta normalització evita que un node amb moltes arestes tingui una escala d'activació molt més gran que un node amb poques connexions. La situació és habitual en futbol: en una fase de construcció pot haver-hi moltes opcions de passada simultànies, mentre que en una transició ràpida el graf pot ser molt més espars.

La capa aprèn una matriu de pesos per relació, W_r , i una branca separada per al missatge propi:

$$H'_{t,v} = W_{\text{self}} H_{t,v} + \sum_{r=1}^R \sum_{u=1}^N \hat{A}_t^{(r)}[v, u] H_{t,u} W_r.$$

Després de la propagació espacial, cada bloc aplica un transformador temporal. El tensor $H \in \mathbb{R}^{B \times T \times N \times D}$ es reorganitza com $B \cdot N$ seqüències independents de longitud T i dimensió D :

$$B \times T \times N \times D \longrightarrow (B N) \times T \times D.$$

Així, l'atenció temporal modela l'evolució de cada agent al llarg de la finestra, mentre que l'intercanvi entre agents ja s'ha produït a la R-GCN del mateix bloc. S'utilitzen quatre caps d'atenció, i la subxarxa interna del transformador té dimensió $4D = 512$. En un cap d'atenció, l'operació es pot escriure com

$$\text{Att}(Q, K, V) = \text{softmax} \left(\frac{QK^\top}{\sqrt{d_h}} + M \right) V,$$

on M és la màscara derivada dels fotogrames vàlids: les posicions no vàlides reben un valor molt negatiu abans de la normalització exponencial i, per tant, no contribueixen a l'atenció.

Un cop aplicats els blocs espai-temporals, el codificador encara disposa d'una representació per a cada fotograma i per a cada node. Abans d'alimentar les capçaleres especialitzades, cal reduir aquest tensor a un únic vector global per mostra,

$$h_b \in \mathbb{R}^D.$$

Aquesta operació es duu a terme mitjançant un mecanisme d'agregació sobre els nodes del darrer fotograma vàlid de la finestra. La tria d'aquest instant és coherent amb la tasca de predicció, ja que és el punt temporal a partir del qual s'anticipa la fase següent; la informació anterior ja ha estat incorporada pel transformador temporal.

S'han considerat dues formes d'agregació. La primera és una mitjana ponderada centrada en la pilota. Si $h_{b,n}$ és la representació del node n al darrer fotograma vàlid i $d_{b,n}$ és la seva distància a la pilota, es defineix un pes gaussià

$$w_{b,n} = \frac{\exp \left(-d_{b,n}^2 / (2\sigma^2) \right)}{\sum_{m=1}^N \exp \left(-d_{b,m}^2 / (2\sigma^2) \right)},$$

i el vector global s'obté com

$$h_b = \sum_{n=1}^N w_{b,n} h_{b,n}.$$

Aquesta formulació introdueix una hipòtesi futbolística senzilla: els jugadors més propers a la pilota solen tenir una influència més directa sobre la continuació immediata de la jugada.

La segona opció és una agregació per atenció. En aquest cas, la representació de la pilota s'utilitza com a consulta, mentre que les representacions de tots els nodes actuen com a claus i valors:

$$q_b = W_Q h_{b,\text{pilota}}, \quad k_{b,n} = W_K h_{b,n}, \quad v_{b,n} = W_V h_{b,n}.$$

Els pesos d'atenció es calculen com

$$\alpha_{b,n} = \text{softmax}_n \left(\frac{q_b k_{b,n}^\top}{\sqrt{D}} \right),$$

i la representació global és

$$h_b = \sum_{n=1}^N \alpha_{b,n} v_{b,n}.$$

A diferència de la mitjana gaussiana, aquest mecanisme no fixa manualment la importància de cada node a partir de la distància, sinó que permet que el model aprengui quins jugadors són més rellevants per resumir l'estat de la jugada. Totes dues estratègies mantenen la pilota com a referència central, però la segona ofereix més flexibilitat perquè la rellevància d'un jugador pot dependre del context tàctic i no només de la seva proximitat espacial.

4.2.6 Objectius supervisats i cascada de capçaleres

Un cop el codificador ha resumit la finestra observada en una representació global, aquesta informació s'ha de transformar en les diferents prediccions associades. Tot seguit es presenten conjuntament els objectius supervisats i les capçaleres que els calculen. Com s'ha especificat prèviament, primer s'estima el tipus de fase posterior i aquesta predicció s'incorpora a la representació que reben les altres tres capçaleres.

La primera tasca consisteix a predir el tipus de la fase següent. Quan la transició no correspon a una pausa llarga, l'etiqueta coincideix amb la categoria tàctica de la fase posterior. El vocabulari utilitzat es defineix a la Secció 3 i conté nou classes:

$$K_{\text{fase}} = 9.$$

La classe **stoppage** no actua com una categoria residual, sinó que representa explícitament les situacions en què una interrupció llarga trenca la continuïtat tàctica entre la fase observada i la posterior.

Per calcular aquesta predicció, la capçalera rep el vector global $h \in \mathbb{R}^{128}$, que és la representació amb què el codificador resumeix tota la finestra observada. Després d'aplicar-hi una normalització de capa i un perceptró multicapa, s'obtenen nou puntuacions no normalitzades:

$$z_{\text{fase}} = \text{MLP}_{\text{fase}}(\text{LN}(h)) \in \mathbb{R}^9,$$

on MLP denota un perceptró multicapa i LN, una normalització de capa. Aquesta sortida s'entrena mitjançant entropia creuada sobre les nou classes.

Les puntuacions no es transformen en una única classe discreta abans d'alimentar les capçaleres posteriors. En canvi, la distribució de probabilitat es projecta sobre una matriu d'*embeddings* entrenable⁴:

$$e_{\text{fase}} = \text{softmax}(z_{\text{fase}}) E, \quad E \in \mathbb{R}^{9 \times 16}.$$

Aquest mecanisme conserva la incertesa de la classificació. Per exemple, si el model assigna probabilitats semblants a **transition** i **quick.break**, les capçaleres següents reben una combinació de totes dues representacions en lloc d'una decisió discreta.

El vector condicionat h_{cond} es construeix concatenant el vector global h , que resumeix la finestra observada, amb la incrustació (*embedding* en anglès) e_{fase} derivada de la predicció anterior:

$$h_{\text{cond}} = h \parallel e_{\text{fase}} \in \mathbb{R}^{128+16} = \mathbb{R}^{144}.$$

Aquesta nova representació alimenta les capçaleres de pausa llarga, canvi de possessió i trajectòria.

La categoria de la fase posterior no determina per si sola si la jugada mantindrà la continuïtat temporal ni quin equip tindrà la possessió. Per aquest motiu, s'introdueixen dues tasques binàries auxiliars. La primera distingeix les transicions ordinàries de les interrupcions prolongades, mentre que la segona identifica si els equips intercanvien els papers ofensiu i defensiu. A més de completar la descripció de la transició, totes dues tasques obliguen el codificador compartit a representar informació que no queda recollida explícitament per l'objectiu de trajectòria.

El temps fins a l'inici de la fase següent es calcula com

$$\Delta t_{\text{proper}} = \frac{f_{\text{start}}^{\text{next}} - t}{10}.$$

⁴En aquest context, una matriu d'*embeddings* és una matriu de paràmetres entrenables en què cada fila representa una classe possible mitjançant un vector. En projectar-hi la distribució de probabilitat, s'obté una representació vectorial suau que conserva informació sobre totes les classes, i no només sobre la classe més probable.

Quan aquest interval supera els 30 s, la mostra es marca com a pausa llarga mitjançant una funció indicadora⁵:

$$y_{\text{pause}} = \mathbf{1}_{\{\Delta t_{\text{proper}} > 30 \text{ s}\}}.$$

En aquest cas, l'objectiu de fase es fixa com a **stoppage** i la trajectòria queda exclosa del càlcul de la pèrdua. Una interrupció d'aquesta durada trenca la continuïtat de la jugada, ja que les posicions posteriors poden respondre a una represa reglamentària, una substitució o un reajust tàctic que no es pot inferir a partir de la cinemàtica observada. La capçalera de pausa evita, per tant, exigir una trajectòria determinista en situacions en què l'evolució posterior depèn de factors externs a la finestra d'entrada.

El canvi de possessió es defineix com

$$y_{\text{poss}} = \mathbf{1}_{\{\text{equip}_{\text{poss}}^{\text{curr}} \neq \text{equip}_{\text{poss}}^{\text{next}}\}}.$$

Aquesta predicció és rellevant perquè un canvi de possessió modifica l'organització col·lectiva, és a dir, l'equip que atacava passa a defensar i l'altre assumeix la iniciativa ofensiva. A més, l'etiqueta de fase descriu el comportament de l'equip en possessió, però no especifica quin equip ocuparà aquest paper en la fase posterior. Aquesta capçalera resol l'ambigüitat i complementa la classificació tàctica.

Per calcular totes dues prediccions, cada capçalera aplica el seu propi perceptró multicapa al vector condicionat $h_{\text{cond}} \in \mathbb{R}^{144}$, format per la representació global del codificador i la incrustació de la fase estimada:

$$z_{\text{pause}} = \text{MLP}_{\text{pause}}(\text{LN}(h_{\text{cond}})), \quad z_{\text{poss}} = \text{MLP}_{\text{poss}}(\text{LN}(h_{\text{cond}})).$$

Les probabilitats resultants s'obtenen aplicant la funció sigmoide⁶ als logits corresponents:

$$\begin{aligned} \hat{p}_{\text{pause}} &= \sigma(z_{\text{pause}}) = P(\Delta t_{\text{proper}} > 30 \text{ s} \mid h_{\text{cond}}), \\ \hat{p}_{\text{poss}} &= \sigma(z_{\text{poss}}) = P(y_{\text{poss}} = 1 \mid h_{\text{cond}}). \end{aligned}$$

Per altra banda, la trajectòria objectiu conté les posicions futures dels 23 nodes per a un màxim de $K = 100$ passos:

$$S_{k,n} = p_{t+ks,n}, \quad k = 1, \dots, K.$$

Només es consideren vàlids els passos que no superen l'inici de la fase següent. Si g_b és el fotograma en què comença aquesta fase per a la mostra b , la màscara temporal es defineix com

$$M_{b,k} = \mathbf{1}_{\{t_b + ks \leq g_b\}}.$$

Aquesta màscara permet utilitzar tensors de mida fixa sense perdre la durada real de cada transició. Sense aplicar-la, el model seria penalitzat per prediccions posteriors al límit de la fase que es vol anticipar.

La capçalera genera posicions absolutes a partir de desplaçaments respecte de la posició actual:

$$\hat{S}_{k,n} = S_{0,n} + \Delta \hat{S}_{k,n}.$$

Per a cada mostra, node i pas futur, el perceptró multicapa rep el vector condicionat h_{cond} , la posició actual del node $S_{0,n}$ i l'horitzó temporal corresponent:

$$[h_{\text{cond}}, S_{0,n}, \Delta t_k], \quad \Delta t_k = k \cdot 0.3 \text{ s}.$$

⁵La notació $\mathbf{1}_{\{\cdot\}}$ representa una funció indicadora: pren el valor 1 quan es compleix la condició escrita al subíndex i el valor 0 en cas contrari.

⁶En aquest context, $\sigma(\cdot)$ denota la funció sigmoide, definida com $\sigma(x) = \frac{1}{1+e^{-x}}$. Aquesta funció transforma un valor real en un valor dins l'interval $(0, 1)$, motiu pel qual és adequada per representar una probabilitat en tasques binàries.

La implementació permet dues variants d'aquesta capçalera. En la variant determinista, el perceptró multicapa retorna únicament dos valors per a cada node i horitzó, corresponents al desplaçament mitjà $(\Delta x, \Delta y)$. La trajectòria resultant s'interpreta com una predicció puntual. En la variant probabilística, la mateixa capçalera retorna quatre valors:

$$(\Delta x, \Delta y, \log \sigma_x, \log \sigma_y).$$

Els dos primers defineixen la mitjana de la posició futura,

$$\mu_{k,n} = S_{0,n} + \Delta \hat{S}_{k,n},$$

mentre que σ_x i σ_y modelitzen la incertesa associada a cada coordenada. Així, la predicció deixa de representar només una trajectòria única i passa a expressar també la confiança del model en aquesta trajectòria. En termes pràctics, dues mostres poden tenir una mitjana semblant però una incertesa diferent: una σ petita indica que el model concentra la probabilitat al voltant de la trajectòria predita, mentre que una σ més gran reflecteix que aquella posició futura és més ambigua. Aquesta extensió és especialment natural en un problema d'horitzó variable: els passos més llunyans poden ser més incerts que una simple continuació cinemàtica.

4.2.7 Funcions de pèrdua

Un cop definides les sortides de les diferents capçaleres, cal establir com es combinen els seus errors per actualitzar conjuntament el codificador compartit.

La pèrdua total del codificador és una suma ponderada de les diferents funcions de pèrdua de les diferents tasques que depenen d'ell:

$$\mathcal{L} = \lambda_{\text{fase}} \mathcal{L}_{\text{fase}} + \lambda_{\text{pause}} \mathcal{L}_{\text{pause}} + \lambda_{\text{possession}} \mathcal{L}_{\text{possession}} + \lambda_{\text{traj}} \mathcal{L}_{\text{traj}}.$$

Durant la fase d'experimentació s'han provat diferents pesos però sempre tenint en compte el rang de valors que pot prendre cada funció de pèrdua per tal d'ajustar els pesos consegüentment. La pèrdua $\mathcal{L}_{\text{fase}}$ és una entropia creuada sobre les nou classes de fase. Per a cada mostra b , la capçalera de fase produeix un vector de logits

$$z_b = (z_{b,1}, z_{b,2}, \dots, z_{b,K}) \in \mathbb{R}^K, \quad K = 9,$$

on $z_{b,c}$ és la puntuació no normalitzada assignada a la classe c . Si $y_b \in \{1, \dots, K\}$ denota la classe real de la mostra i w_c és el pes associat a la classe c , la pèrdua per mostra es defineix com

$$\ell_{\text{fase}}^{(b)} = -w_{y_b} \log \left(\frac{\exp(z_{b,y_b})}{\sum_{c=1}^K \exp(z_{b,c})} \right).$$

La pèrdua del lot s'obté fent la mitjana sobre les mostres del batch.

Com que les classes no apareixen amb la mateixa freqüència, els pesos es calculen a partir del conjunt d'entrenament:

$$w_c = \frac{N_{\text{total}}}{K \cdot \max(n_c, n_{\min})}, \quad K = 9, \quad n_{\min} = 5.$$

El valor $n_{\min} = 5$ evita pesos excessius quan una classe apareix molt poc.

Pel que fa a les dues capçaleres binàries, totes dues s'entrenen mitjançant entropia creuada binària aplicada a les puntuacions no normalitzades. Per a una etiqueta $y \in \{0, 1\}$ i una puntuació z , la pèrdua ponderada és

$$\mathcal{L}_{\text{pause}} = \mathcal{L}_{\text{possession}} = -w_+ y \log \sigma(z) - (1 - y) \log(1 - \sigma(z)), w_+^7 = \frac{N_{\text{neg}}}{N_{\text{pos}}}.$$

⁷ w_+ és el pes de la classe positiva i es calcula sobre el conjunt d'entrenament. Aquesta ponderació compensa el desequilibri entre classes.

Finalment, la pèrdua de trajectòria $\mathcal{L}_{\text{traj}}$ es calcula sobre coordenades normalitzades per una escala espacial de 50 m. Aquest valor aproxima l'ordre de magnitud màxim de les coordenades d'un camp de 105 m per 68 m centrat a l'origen. Dividir per 50 porta els errors a una escala més estable per al gradient, sense canviar les mètriques finals, que es calculen en metres. Sigui $M_{b,k}$ la màscara temporal de passos vàlids i

$$q_b = 1 - y_{\text{pause}}^{(b)}.$$

En la variant determinista, en què la capçalera retorna una predicció puntual $\hat{S}$, la pèrdua implementada és

$$\mathcal{L}_{\text{traj}} = \frac{\sum_b q_b \left[\frac{\sum_k M_{b,k} \left(\frac{1}{2N} \sum_{n=1}^N \left\| \frac{\hat{S}_{b,k,n} - S_{b,k,n}}{50} \right\|_2^2 \right)}{\max(1, \sum_k M_{b,k})} \right]}{\max(1, \sum_b q_b)}.$$

La normalització primer per passos i després per mostres evita que una fase llarga tingui més pes només pel fet de contenir més horitzons supervisats. Les pauses llargues queden completament excloses mitjançant $q_b = 0$.

Quan s'activa la variant probabilística, $\hat{S}$ s'interpreta com la mitjana μ d'una distribució gaussiana diagonal i la capçalera també prediu $\log \sigma$ per coordenada. L'estructura de màscares és la mateixa, però el terme quadràtic local se substitueix per la versemblança negativa gaussiana del residu normalitzat

$$r_{b,k,n,c} = \frac{S_{b,k,n,c} - \mu_{b,k,n,c}}{50}.$$

Sense el terme constant, que no afecta l'optimització, aquesta pèrdua local és

$$\frac{1}{2N} \sum_{n=1}^N \sum_{c \in \{x,y\}} \left[\frac{1}{2} r_{b,k,n,c}^2 \exp(-2 \log \sigma_{b,k,n,c}) + \log \sigma_{b,k,n,c} \right].$$

Aquest terme penalitza les prediccions errònies amb poca incertesa i, alhora, evita que el model augmenti σ de manera indiscriminada.

5 Resultats i avaluació

Aquest capítol presenta i analitza els resultats de les dues aproximacions desenvolupades al treball. La primera avalua la predicció de trajectòries sobre un horitzó fix de tres segons, mentre que la segona estudia la predicció de transicions tàctiques amb horitzó variable. Per aquest motiu, els resultats s'introdueixen inicialment per separat i després es poden interpretar com dues lectures complementàries de la dinàmica del joc.

5.1 Configuració experimental i mètriques d'avaluació

Abans de presentar els resultats, cal concretar les condicions sota les quals s'han optimitzat els models. Les dues variants del model STGCN comparteixen exactament el mateix protocol, de manera que la comparació entre elles no queda condicionada per una configuració d'entrenament diferent. El model de múltiples capçaleres manté els mateixos valors generals per preservar un criteri experimental homogeni al llarg del treball. La Taula 1 resumeix aquesta configuració comuna.

Taula 1: Configuració d'entrenament utilitzada per als models.

Hiperparàmetre	Valor
Optimitzador	Adam (models STGCN) i AdamW (model de múltiples capçaleres)
Taxa d'aprenentatge inicial	10^{-3}
Regularització o decaïment de pesos	10^{-4}
Mida del lot	32
Nombre màxim d'èpoques	50
Retallada de gradients	$\ \nabla\ _{\max} = 5$
Planificador de la taxa d'aprenentatge	<i>ReduceLROnPlateau</i> , amb factor 0,5 i paciència de 5 èpoques
Aturada anticipada	Paciència de 10 èpoques
Pesos de la pèrdua multitasca	$\lambda_{\text{traj}} \in [50, 200]$, $\lambda_{\text{fase}} \in [1, 5]$, $\lambda_{\text{pause}} \in [0,5, 1]$ i $\lambda_{\text{poss}} \in [0,5, 1]$
Mètode d'agregació	Atenció sobre la pilota Mitjana ponderada gaussiana centrada en la pilota

La configuració combina una fase inicial d'aprenentatge relativament ràpida amb un refinament progressiu. La taxa inicial de 10^{-3} permet recórrer l'espai de paràmetres amb actualitzacions prou significatives, mentre que la seva reducció a la meitat després de cinc èpoques sense millora adapta la resolució de l'optimització quan la convergència comença a estabilitzar-se. La paciència evita interpretar una oscil·lació puntual de la validació com un estancament real.

El límit de 50 èpoques actua com una cota superior, però el nombre efectiu d'èpoques el determina l'aturada anticipada. Si la pèrdua de validació no millora durant deu èpoques consecutives, es conserva el millor estat assolit i s'interromp l'entrenament. Aquest criteri redueix el risc de sobreajustament i fa que la selecció del model depengui del comportament sobre dades no utilitzades per actualitzar els pesos.

L'optimitzador és l'única diferència principal entre les dues aproximacions. Els models STGCN utilitzen Adam amb regularització L_2 , mentre que el model de múltiples capçaleres

empra AdamW, que desacobla el decaïment dels pesos de l'actualització adaptativa del gradient. En tots dos casos, el coeficient és 10^{-4} . La retallada de la norma del gradient a 5 completa aquest control d'estabilitat i és especialment pertinent en l'arquitectura de múltiples capçaleres, ja que les diferents funcions de pèrdua actualitzen conjuntament el codificador compartit. Per altra banda, en el model de múltiples capçaleres, la pèrdua que actualitza el codificador compartit és una suma ponderada dels objectius supervisats:

$$\mathcal{L} = \lambda_{\text{fase}} \mathcal{L}_{\text{fase}} + \lambda_{\text{pause}} \mathcal{L}_{\text{pause}} + \lambda_{\text{poss}} \mathcal{L}_{\text{poss}} + \lambda_{\text{traj}} \mathcal{L}_{\text{traj}}.$$

La trajectòria rep el pes més elevat perquè és l'objectiu principal de la segona aproximació i perquè la capçalera genera desplaçaments en metres respecte de la posició actual, mentre que la pèrdua s'aplica sobre la posició resultant amb el residu normalitzat per una escala espacial de 50m. Aquesta normalització estabilitza el gradient, però també fa necessari ponderar la trajectòria perquè la seva contribució no quedi diluïda davant les pèrdues de classificació. La fase següent també manté un pes rellevant, ja que la seva representació es concatena amb el vector latent i condiciona la resta de capçaleres. En canvi, les tasques binàries de pausa i canvi de possessió reben pesos menors perquè són objectius més simples i tendeixen a assolir abans el seu sostre de rendiment. En termes d'optimització, el gradient sobre els paràmetres compartits és una combinació ponderada dels gradients de cada tasca,

$$\nabla_{\theta} \mathcal{L} = \sum_j \lambda_j \nabla_{\theta} \mathcal{L}_j,$$

de manera que el model pot reduir simultàniament errors de naturalesa diferent. Els pesos baixos no eliminen una tasca.

Com s'ha explicat a 4.2.5, el codificador pot obtenir la representació global de la finestra mitjançant dos mètodes d'agregació: una mitjana ponderada per la distància a la pilota o un mecanisme d'atenció que pren la pilota com a referència. En els experiments s'han provat totes dues opcions i els resultats obtinguts són molt similars, amb un avantatge lleuger per al mètode d'atenció sobre la pilota.

Per avaluar els models s'utilitzen dues mètriques estàndard en predicció de trajectòries. L'ADE (*Average Displacement Error*) és l'error euclidià mitjà sobre tots els fotogrames predits i tots els nodes:

$$\text{ADE} = \frac{1}{T_{\text{pred}} \cdot N} \sum_{t=1}^{T_{\text{pred}}} \sum_{n=1}^N \left\| \hat{p}_n^{(t)} - p_n^{(t)} \right\|_2.$$

En aquesta expressió, T_{pred} és el nombre de fotogrames futurs predits, N és el nombre de nodes, $\hat{p}_n^{(t)}$ és la posició predita del node n a l'instant futur t , i $p_n^{(t)}$ és la posició real. La norma $\| \cdot \|_2$ correspon a la distància euclidiana entre totes dues posicions.

La mètrica FDE (*Final Displacement Error*) és l'error euclidià al darrer fotograma predit, mitjà sobre tots els nodes:

$$\text{FDE} = \frac{1}{N} \sum_{n=1}^N \left\| \hat{p}_n^{(T_{\text{pred}})} - p_n^{(T_{\text{pred}})} \right\|_2.$$

L'error per pas $\text{err}(t)$ és l'error mitjà sobre tots els nodes i totes les mostres en un horitzó concret t :

$$\text{err}(t) = \frac{1}{|\mathcal{S}_t|} \sum_{s \in \mathcal{S}_t} \frac{1}{N} \sum_{n=1}^N \left\| \hat{p}_{s,n}^{(t)} - p_{s,n}^{(t)} \right\|_2,$$

on $\mathcal{S}_t$ és el conjunt de mostres amb el pas t vàlid. En el model STGCN, els 30 passos són vàlids per a totes les mostres, de manera que $|\mathcal{S}_t|$ és constant i coincideix amb les 6913 seqüències vàlides del conjunt de test.

L'error no es distribueix uniformement: els primers fotogrames futurs, entre 0,1 i 0,5 segons, presenten errors petits, mentre que els darrers, entre 2,5 i 3,0 segons, acumulen més incertesa. Per tant, l'ADE pot oferir una impressió optimista del rendiment als horitzons més llargs si s'interpreta sense aquesta desagregació temporal.

Per contextualitzar els resultats de la primera aproximació, també és útil disposar de models de referència sense aprenentatge. El primer manté constant l'última posició observada,

$$\hat{p}_n^{(t+k)} = p_n^{(t)},$$

i permet mesurar fins a quin punt la tasca exigeix anticipar el moviment. El segon és una extrapolació de velocitat constant: es calcula la velocitat recent de cada node a partir dels darrers fotogrames observats i es projecta linealment cap al futur, utilitzant la cinemàtica del moviment rectilini uniforme.

$$\hat{p}_n^{(t+k)} = p_n^{(t)} + k \Delta t \hat{v}_n.$$

En aquesta expressió, $\hat{v}_n$ és la velocitat estimada del node n al tram final de la finestra d'entrada i Δt és el pas temporal entre dos fotogrames consecutius. Si una xarxa neuronal no millorés clarament aquestes referències, seria difícil atribuir-li una capacitat efectiva d'aprendre dependències espaiotemporals.

5.2 Primera aproximació: predicció de trajectòries amb horitzó fix

La primera aproximació s'avalua comparant les dues variants del model STGCN, amb graf estàtic i amb graf dinàmic, sobre la mateixa tasca de predicció a tres segons. La Taula 2 resumeix el rendiment obtingut sobre el conjunt de test i inclou els dos models de referència descrits anteriorment.

Taula 2: Comparació del rendiment sobre el conjunt de test de 6.913 seqüències.

Model	ADE (m)	FDE (m)	Δ ADE (%)	Δ FDE (%)
Posició constant	3.098	5.745	-73.5	-35.6
Velocitat constant	1.786	4.238	0.0	0.0
STGCN estàtic	1.555	3.005	12.9	29.1
STGCN dinàmic	1.264	2.882	29.2	32.0

Les columnes Δ ADE i Δ FDE expressen la reducció relativa de l'error respecte del model de velocitat constant. El model de posició constant obté valors negatius perquè ignora completament la dinàmica recent dels jugadors i de la pilota, de manera que empitjora la referència cinemàtica. La velocitat constant redueix de manera clara aquest error i constitueix una referència més exigent, ja que aprofita la continuïtat local del moviment sense aprendre cap patró tàctic ni cap dependència entre nodes. Respecte d'aquesta referència, el model STGCN estàtic redueix l'ADE un 12,9 % i la mètrica FDE en un 29,1 %, mentre que el model STGCN dinàmic eleva aquestes reduccions fins al 29,2 % i el 32,0 %, respectivament. Això indica que el model no es limita a prolongar la cinemàtica recent, sinó que aprofita informació espaiotemporal addicional.

La comparació entre les dues variants del model STGCN manté la mateixa tendència. El graf dinàmic obté un error més baix que l'estàtic en les dues mètriques, amb una reducció relativa del 18,7 % en l'ADE i del 4,1 % en la mètrica FDE. Aquest resultat indica que actualitzar les relacions espacials al llarg de la seqüència ajuda a millorar la trajectòria mitjana, tot i que el guany és més moderat en el darrer instant de l'horitzó. Aquesta diferència és coherent amb la dificultat creixent de predir a tres segons vista, on l'acumulació d'incertesa redueix l'avantatge que aporta una representació més informada del graf.

Tot i que les mètriques globals mostren un rendiment favorable del model dinàmic, cal complementar-les amb una anàlisi de l'error per horitzó temporal. Aquesta lectura evita interpretar l'ADE com si tots els instants futurs tinguessin la mateixa dificultat.




Figura 4: Error per horitzó temporal dels models estàtic i dinàmic.

La Figura 4 confirma que l'error augmenta a mesura que la predicció s'allunya de l'instant observat. Tot i això, el model dinàmic manté un error inferior al de l'estàtic durant tot l'horitzó.

A continuació es mostra l'evolució de l'entrenament de les dues variants. Les corbes permeten comprovar si la diferència observada al conjunt de test respon a un procés d'aprenentatge estable o a una oscil·lació puntual de la validació.

La Figura 10 de l'Annex C.3 mostra que ambdós models redueixen progressivament la funció de pèrdua i la mètrica FDE durant les primeres èpoques, fet que indica que són capaços d'extreure patrons útils de les dades d'entrenament. En les darreres èpoques, les corbes tendeixen a estabilitzar-se, especialment en validació, de manera que les millores passen a ser cada vegada més petites. Aquest comportament pot estar relacionat amb les limitacions de capacitat de l'arquitectura per capturar dependències més complexes, però també amb la dificultat intrínseca de la tasca, ja que la incertesa augmenta a mesura que s'allarga l'horitzó temporal.

Tot seguit, es complementa l'anàlisi dels resultats amb una visualització qualitativa del model STGCN.




Figura 5: Validació qualitativa dels models STGCN estàtic i dinàmic sobre tres seqüències del conjunt de prova. Per a cada seqüència es mostren les trajectòries reals i les trajectòries predites dels jugadors i de la pilota durant l'horitzó de tres segons. A cada camp es mostren la posició de cada node a l'instant de predicció (cercles), el seu rastre d'història (línia tènue), la trajectòria futura (discontínua, acolorida per equip) i la posició final (quadrat per als jugadors, estrella per a la pilota)

En els primers fotogrames futurs, la predicció segueix de prop el moviment observat, mentre que la separació augmenta a mesura que avança l'horitzó. Aquesta evolució és coherent amb el creixement de l'error temporal de la Figura 4. A la Secció 7 es fa un anàlisi més detallat de la primera seqüència de la Figura 5.

5.3 Segona aproximació: representació tàctica i predicció amb horitzó variable

La segona aproximació s'avalua sobre una tasca més àmplia que la predicció amb horitzó fix. El model ha de representar l'estat tàctic de la fase actual, anticipar la fase següent, detectar interrupcions llargues i canvis de possessió, i predir les trajectòries fins al començament de la propera fase. Per aquest motiu, els resultats no es poden llegir únicament com un error mitjà de posició: cal combinar l'anàlisi de la trajectòria, el comportament de les capçaleres de classificació i la qualitat de la representació apresada pel codificador.

La trajectòria és el primer element que convé analitzar, perquè és l'objectiu més directament comparable amb la primera aproximació. A diferència del model STGCN, però, aquí l'horitzó no és fix: cada mostra es supervisa només fins a l'inici de la fase tàctica següent. Això fa que els errors dels primers segons i els errors dels horitzons llargs tinguin una naturalesa diferent. La Taula 3 separa l'error en quatre trams temporals i compara dues referències sense aprenentatge amb dues variants de la capçalera de trajectòria. La primera variant és determinista i s'entrena amb error quadràtic mitjà, que en endavant s'identifica com a MSE. La segona és probabilística i s'entrena amb log-versemblança negativa gaussiana, identificada com a NLL.

Taula 3: Comparació de l'error per horitzó de la predicció de trajectòria entre els models de referència, la capçalera determinista i la capçalera probabilística sobre el conjunt de test.

Tram d'horitzó	Pos. const.	Vel. const.	MSE	NLL	Millora
0–3 s	3,62	2,55	3,04	2,52	+17,1 %
3–8 s	10,26	11,91	8,54	8,10	+5,1 %
8–15 s	18,43	30,50	15,14	15,48	-2,2 %
> 15 s	22,69	51,14	16,25	17,11	-5,3 %
ADE	5,57	6,63	4,23	3,78	+10,6 %
FDE	8,56	12,70	7,20	6,38	+11,4 %

La columna de millora mesura la reducció relativa de l'error de la variant NLL respecte de la variant MSE, de manera que els valors negatius indiquen un empitjorament. Les files ADE i FDE resumeixen, respectivament, l'error mitjà de trajectòria i l'error al darrer pas vàlid de cada mostra, mentre que les files superiors desglossen l'error segons el tram temporal de cada pas futur. La lectura per trams mostra que la velocitat constant és una referència competitiva només en els primers segons, però es degrada ràpidament quan l'horitzó s'allarga. Aquest comportament és coherent amb la naturalesa de les transicions tàctiques: una fase no evoluciona com una prolongació inercial del moviment recent, sinó que pot incloure frenades, canvis de direcció, passades o reorganitzacions col·lectives. La posició constant, tot i ser una referència molt simple, resulta més estable en els trams llargs perquè no acumula una velocitat inicial que pot deixar de ser vàlida pocs segons després.

Les dues variants amb xarxes neuronals milloren clarament les referències globals, i la variant probabilística obté el millor resultat agregat. La millora és especialment clara entre 0 i 3 segons, on redueix l'error un 17,1 % respecte de la formulació determinista. Això suggereix que predir també una incertesa per coordenada ajuda quan el futur encara conserva una relació directa amb l'estat observat. En canvi, en els horitzons de més de 8 segons, la variant MSE conserva un error lleugerament inferior (pràcticament negligible).

La Figura 11 de l'Annex C.3 mostra que l'aprenentatge del model amb horitzó variable és més progressiu que en la variant STGCN. L'error de trajectòria i l'error final disminueixen de manera clara durant les primeres èpoques, però no s'estabilitzen tan aviat com en els models STGCN; la millor validació s'assoleix al voltant de l'època 38. Aquest comportament suggereix que l'arquitectura multi-head encara disposa de marge d'aprenentatge quan els models amb horitzó fix ja han començat a saturar-se. Alhora, la separació gradual entre les corbes d'entrenament i validació indica que aquest marge no és il·limitat: el model continua ajustant-se a les dades d'entrenament, mentre que la millora en validació es fa més lenta. Les oscil·lacions puntuals de la pèrdua NLL i de la pèrdua total no trenquen aquesta tendència general, però mostren que l'optimització és més sensible que en el cas STGCN, possiblement per la combinació de múltiples objectius i d'un horitzó variable. La mètrica de precisió de la fase i del canvi de possessió també augmenten durant l'entrenament, fet coherent amb la idea que el codificador compartit va incorporant informació tàctica útil per a més d'una capçalera.

Pel que fa a Les capçaleres tàctiques que prediuen el tipus de fase següent, la pausa llarga i el canvi de possessió aporten una lectura complementària a la de la trajectòria, i la seva interpretació no pot obviar la seva distribució de classes en el conjunt de test. El tipus de fase reparteix les 1356 mostres entre nou categories molt desiguals, amb la creació com a més freqüent (399 mostres, el 29,4 %) i tres categories gairebé residuals (transició, contraatac ràpid i pilota aturada, que plegades no arriben al 4 %). La pausa llarga és clarament minoritària, amb només 114 positius sobre 1356 (8,4 % de prevalença). El canvi de possessió, en canvi, s'avalua sobre les 1242 mostres sense pausa i amb possessió definida, on la distribució és pràcticament equilibrada (646 canvis, el 52,0 %).

Taula 4: Resultats de les capçaleres tàctiques sobre el conjunt de test.

Capçalera	Pèrdua	Precisió
Tipus de la fase següent	1,474	0,465
Pausa llarga	0,249	0,908
Canvi de possessió	0,570	0,759

La Taula 4 mostra uns resultats per les capçaleres binàries estables i una classificació de fase clarament més difícil, com és esperable pel nombre de classes i per la proximitat semàntica entre algunes transicions. Aquests valors són molt propers als observats en la validació i del mateix ordre que els d'entrenament a la Figura 11. Això indica que el model està generalitzant correctament.

Finalment, s'avalua si el vector global produït pel codificador conté una estructura tàctica coherent. Per fer aquesta anàlisi es van fer passar pel codificador totes les fases tàctiques de tots els partits del conjunt de dades i se'n va desar el vector latent associat. D'aquesta manera, l'avaluació de l'espai latent es basa en els embeddings obtinguts sistemàticament per a totes les mostres disponibles. Una representació adequada no hauria de limitar-se a reduir la funció de pèrdua, sinó que hauria d'organitzar mostres tàcticament semblants en regions properes de l'espai latent. Aquesta propietat s'avalua mitjançant la puresa de veïnatge i una projecció bidimensional.

La puresa de veïnatge és la fracció dels k veïns més similars, segons la similitud cosinus⁸ entre vectors latents, que comparteixen el mateix valor d'un atribut tàctic. Com que una variable

⁸La similitud cosinus mesura la proximitat angular entre dos vectors:

$$\text{sim}_{\cos}(u, v) = \frac{u \cdot v}{\|u\|_2 \|v\|_2}.$$

Pren valors entre -1 i 1 , on valors propers a 1 indiquen vectors amb una orientació molt semblant. A diferència de la distància euclidiana, dona més importància a la direcció de la representació que no pas a la seva magnitud.

desbalancejada pot presentar una puresa elevada només pel pes de la classe majoritària, el valor observat es compara amb la probabilitat de coincidència sota una assignació aleatòria de veïns. La Taula 5 recull els resultats sobre les 13683 mostres del conjunt de dades, amb $k = 10$.

Atribut	Puresa	Aleatori	Ràtio
Tipus de la propera fase (9 classes)	0,535	0,111	4,82×
Indicador de pausa llarga (binari)	0,878	0,500	1,76×
Canvi de possessió (binari)	0,766	0,500	1,53×

Taula 5: Puresa de veïnatge amb $k = 10$ per als tres atributs tàctics considerats. La columna “Ràtio” en mostra el quocient amb la puresa observada.

El tipus de la fase següent presenta el guany relatiu més gran, amb una puresa gairebé cinc vegades superior a l’atzar. La pausa llarga obté la puresa absoluta més elevada, però un increment relatiu menor a causa de la seva naturalesa binària. El canvi de possessió mostra una separació més feble, coherent amb el caràcter més ambigu d’aquesta predicció.

Com a comprovació complementària, els vectors es projecten a dues dimensions mitjançant t-SNE⁹.




Figura 6: Projeccions t-SNE dels vectors latents del codificador, acolorides segons diferents atributs tàctics. Esquerra: tipus de la propera fase tàctica. Centre: indicador de pausa llarga. Dreta: canvi de possessió entre la fase actual i la següent.

La Figura 6 reproduceix visualment el mateix patró que la puresa de veïnatge: la separació és més clara per al tipus de fase i la pausa llarga, mentre que el canvi de possessió presenta una estructura més difusa. En la projecció per tipus de fase apareixen agrupaments coherents amb les classes més freqüents, especialment **create**, **finish** i **build.up**. La projecció de pausa llarga mostra una concentració més localitzada de les mostres associades a interrupcions, mentre que el canvi de possessió queda més barrejat amb la resta. Aquesta diferència és coherent amb la naturalesa de les tasques: una pausa llarga deixa un senyal temporal i contextual més marcat, mentre que el canvi de possessió pot dependre de detalls de la fase posterior que encara no són completament observables en l’instant de predicció. La coherència entre les mètriques de veïnatge i la projecció bidimensional indica que el codificador ha après una representació amb contingut tàctic rellevant.

Finalment s’evalua un exemple de validació qualitativa de diverses seqüències.

⁹t-SNE (*t-Distributed Stochastic Neighbor Embedding*, van der Maaten i Hinton, 2008) és un mètode no lineal de reducció de dimensionalitat orientat a preservar els veïnatges locals.




Figura 7: Exemples qualitatius de predicció de trajectòria sobre tres jugades del partit de test. Cada fila compara la trajectòria real amb els caps entrenats amb MSE i NLL.

La Figura 7 permet interpretar qualitativament el comportament de les dues variants de la capçalera de trajectòria. En la primera seqüència, tant el model entrenat amb MSE com el model entrenat amb NLL generen una predicció tàcticament coherent: el jugador atacant progressa amb pilota i els rivals retrocedeixen per reduir espais en direcció a la porteria que defensen. Tot i això, la trajectòria real suggereix que la pilota acaba sortint del terreny de joc, possiblement després d'un refús, i que el mateix jugador es desplaça cap a la banda per reprendre el joc. Aquest tipus de desenllaç és pràcticament impossible d'anticipar només a partir de la finestra observada i, a més, no seria necessàriament desitjable que el model intentés reproduir-lo si això comportés perdre en situacions més regulars.

La segona seqüència és especialment informativa perquè mostra una situació amb un futur més obert. El posseïdor de la pilota podria filtrar una passada a l'espai cap a un company que es desmarca en paral·lel, però les dues variants del model prediuen que els defensors tancaran aquest espai i que l'atacant continuarà la conducció cap a porteria. Aquest comportament és rellevant sobretot en la resposta defensiva: el moviment del lateral dret, que retrocedeix mantenint-se en la línia de passada, indica que el codificador no només aprèn patrons cinemàtics, sinó també part del context tàctic de la jugada. En la trajectòria real, en canvi, el recorregut de la pilota suggereix una acció més irregular, possiblement una conducció seguida d'una passada interceptada i diversos refusos, fet que explica la forma aparentment caòtica de la pilota en un horitzó de només nou segons.

Finalment, cal destacar que les prediccions MSE i NLL són molt semblants en les tres seqüències. Aquest resultat és coherent amb l'arquitectura del model: les dues variants comparteixen el mateix codificador i, per tant, parteixen d'una mateixa representació tàctica de l'estat del joc. La diferència principal no és el context que interpreten, sinó la manera com la capçalera de trajectòria formula la sortida i la incertesa associada. Es poden consultar més exemples qualitatius de predicció de trajectòries amb ambdós models a l'Annex C.4.

6 Discussió

Els resultats obtinguts s'han d'interpretar tenint en compte que les dues famílies de models no resolen exactament la mateixa tasca. Els models STGCN prediuen una finestra contínua de tres segons a partir d'un historial recent, mentre que el model de múltiples capçaleres prediu una transició entre fases, amb una longitud variable i amb possibles canvis tàctics dins de l'horitzó avaluat. Per tant, els errors de trajectòria no són directament equiparables: serveixen per analitzar cada formulació, però no per establir una comparació absoluta entre arquitectures en igualtat de condicions.

En la primera aproximació, la comparació amb els models de referència mostra que la predicció a curt termini conté una component cinemàtica molt important. La velocitat constant ja redueix clarament l'error respecte de mantenir l'última posició observada, amb un ADE de 1,786 m davant dels 3,098 m de la posició constant. Tot i això, les dues variants del model STGCN superen aquesta referència: el model estàtic obté un ADE de 1,555 m i el dinàmic el redueix fins a 1,264 m. Aquesta diferència indica que la xarxa no es limita a extrapolar velocitats, sinó que aprofita informació espai-temporal addicional. La millora del graf dinàmic respecte de l'estàtic és especialment clara en l'ADE, amb una reducció relativa del 18,7%, mentre que en la mètrica FDE és més moderada, del 4,1%. Aquesta asimetria és coherent amb la dificultat creixent dels últims instants de l'horitzó, on l'avantatge d'una topologia més adaptada a la jugada es veu parcialment limitat per la incertesa del futur.

Aquesta mateixa lectura ajuda a entendre per què cal prudència quan es compara el model STGCN amb el model de múltiples capçaleres. El millor STGCN obté errors molt més baixos en els primers tres segons que el model amb horitzó variable, però aquesta diferència no implica necessàriament que la segona arquitectura modela pitjor el joc. En el cas STGCN, totes les mostres comparteixen un horitzó curt i homogeni. En canvi, en el model de transicions, l'horitzó pot allargar-se fins a trams de més de 15 segons i pot incloure reorganitzacions defensives, passades, intercepcions, refusos o canvis de possessió. Així, l'ADE de 3,78 m i la mètrica FDE de 6,38 m del model probabilístic s'han de llegir dins del context d'una tasca més oberta.

Els models de referència del segon bloc fan visible aquesta diferència de dificultat. La velocitat constant és competitiva només al primer tram temporal, amb 2,55 m entre 0 i 3 segons, però es degrada ràpidament quan l'horitzó s'allarga, fins a 51,14 m en el tram superior a 15 segons. L'assumpció de que els jugadors no es mouen, la posició constant, tot i ser molt simple, és més estable globalment, amb un ADE de 5,57 m i un FDE de 8,56 m, perquè no acumula una velocitat inicial que pot deixar de tenir sentit després d'una transició tàctica. Que el model probabilístic millori aquestes referències i redueixi l'ADE fins a 3,78 m mostra que el codificador aprèn patrons més informatius que la persistència o la inèrcia local del moviment.

La comparació entre les dues capçaleres de trajectòria també aporta matisos. La variant probabilística entrenada amb NLL millora el resultat agregat respecte de la variant determinista, amb una reducció relativa del 10,6% en ADE i de l'11,4% en FDE. El guany és especialment clar entre 0 i 3 segons, on l'error baixa de 3,04 m a 2,52 m. En canvi, a partir dels 8 segons, la variant MSE conserva un avantatge lleu. Aquest resultat suggereix que estimar una incertesa gaussiana per coordenada ajuda quan el futur és encara proper però ambigu, però és insuficient per representar completament els futurs alternatius d'una jugada.

L'anàlisi de l'espai latent complementa aquestes mètriques. La puresa de veïnatge per al tipus de fase següent és 0,535, gairebé cinc vegades per sobre del valor aleatori indicat a la taula, i la pausa llarga arriba a una puresa de 0,878. El canvi de possessió mostra una estructura més feble, amb una puresa de 0,766, però encara superior a la referència aleatòria. Aquests valors, juntament amb la projecció t-SNE, indiquen que el codificador no organitza les mostres únicament per proximitat geomètrica, sinó també segons propietats tàctiques relacionades amb la fase posterior. Això no implica una comprensió completa de la causalitat del joc, però sí que dona suport a la idea que la supervisió multitasca estructura una representació contextual del joc.

7 Conclusions

El treball confirma que les xarxes neuronals sobre grafs són una eina adequada per modelitzar l'evolució espai-temporal dels jugadors i de la pilota. En la primera aproximació, l'adaptació del model STGCN al futbol mostra que incorporar la configuració concreta de cada jugada mitjançant un graf dinàmic representa millor les interaccions que un graf estàtic global. En la segona, la formulació s'amplia cap a transicions tàctiques amb horitzó variable, amb un graf relacional i un codificador compartit per predir trajectòries, tipus de fase, pauses llargues i canvis de possessió. Aquesta supervisió conjunta no només produeix prediccions específiques, sinó que també induïx una representació latent amb estructura tàctica. Així, les dues aproximacions es poden entendre com dos nivells de contextualització del mateix problema: primer la geometria dinàmica del moviment i, després, la seva relació amb l'estructura tàctica del joc.

La validació qualitativa mostra que les mètriques d'error no sempre expliquen tota la qualitat d'una predicció. En el cas del model STGCN, els errors són baixos en finestres curtes, que és precisament l'escenari per al qual s'entrena el model; tanmateix, algunes seqüències indiquen que pot produir trajectòries geomètricament probables però poc coherents amb la intenció de la jugada. A la Figura 5, per exemple, el model anticipa la passada, però projecta el porter cap a la porteria en lloc d'apropar-lo a la recepció. Aquesta resposta és comprensible si el model ha après que, quan la pilota s'acosta i el porter està desplaçat, convé recuperar posició per tancar espais, però no incorpora prou context per entendre que en aquella acció la pilota va dirigida cap a ell. En canvi, en el model de múltiples capçaleres, les prediccions sovint generen continuacions tàcticament raonables encara que no coincideixin exactament amb el desenllaç observat. Per tant, una conclusió important és que l'avaluació quantitativa s'ha de complementar amb una lectura qualitativa: en futbol, una predicció pot tenir més error en metres i, alhora, ser una hipòtesi tàctica més plausible abans que la jugada es resolgui.

També cal considerar que el futbol és un entorn amb un nombre molt gran de possibilitats per a cada acció. Hi intervenen 22 jugadors i la pilota en un espai ampli, amb múltiples decisions possibles en cada instant i amb situacions que poden canviar de manera sobtada, entre d'altres, per una passada o un refús. Per aquest motiu, la qualitat d'un estudi d'aquest tipus depèn en gran mesura de disposar de moltes dades i de cobrir una varietat suficient de contextos tàctics. En aquest treball, però, el conjunt està limitat a deu partits d'una mateixa competició. A més, les etiquetes de fase i possessió s'imposen per la font de dades usada. Per tant, els resultats són consistents dins del marc experimental definit, però haurien de validar-se sobre més partits i altres competicions abans d'extreure conclusions generals en escenaris futbolístics més amplis.

Una altra conclusió rellevant és que una formulació més rica del problema no garanteix necessàriament un millor rendiment en una tasca més simple. El model de múltiples capçaleres incorpora més context tàctic i resol una predicció amb horitzó variable, però això no implica que hagi de superar un model especialitzat en la predicció a tres segons. De fet, el model STGCN està optimitzat directament per a aquest objectiu concret, mentre que el model multi-head reparteix la seva capacitat entre diverses tasques. Aquesta observació és especialment important en un escenari amb recursos limitats: els models utilitzats tenen una mida moderada, amb un nombre de paràmetres comprès aproximadament entre 1,0 i 1,5 milions i s'entrenen sobre només deu partits. En aquest context, tot i que una tasca més ambiciosa pot generar representacions més informatives del joc, això no implica necessàriament obtenir errors més baixos en una avaluació més simple.

Finalment, la principal conclusió metodològica és que la predicció de moviment en futbol no depèn només de la capacitat del model, sinó també de com es defineixen el graf, l'horitzó temporal i els objectius d'aprenentatge. Passar d'una topologia global a una topologia dinàmica millora la predicció a curt termini, mentre que representar el joc mitjançant fases permet abordar un problema més proper a la dinàmica real del partit. Com a continuació natural, seria convenient incorporar futurs alternatius de manera explícita i estudiar amb més profunditat la calibració de la incertesa en les trajectòries predites.


Referències

- [1] Alexandre Alahi, Kratarth Goel, Vignesh Ramanathan, Alexandre Robicquet, Li Fei-Fei, and Silvio Savarese. Social lstm: Human trajectory prediction in crowded spaces. In *2016 IEEE Conference on Computer Vision and Pattern Recognition*, pages 961–971, 2016. doi:[10.1109/CVPR.2016.110](https://doi.org/10.1109/CVPR.2016.110).
- [2] Anatolij Babic, Harshit Bansal, Gianluca Finocchio, Julian Golak, Mark Peletier, Jim Portegies, Clara Stegehuis, Anuj Tyagi, Roland Vincze, and William Weimin Yoo. Scisports: Learning football kinematics through two-dimensional tracking data. *arXiv preprint arXiv:1808.04550*, 2018. doi:[10.48550/arXiv.1808.04550](https://doi.org/10.48550/arXiv.1808.04550).
- [3] Guillem Capellera, Luis Ferraz, Antonio Rubio, Antonio Agudo, and Francesc Moreno-Noguer. Footbots: A transformer-based architecture for motion prediction in soccer. *arXiv preprint arXiv:2406.19852*, 2024. Publicat a IEEE ICIP 2024. doi:[10.48550/arXiv.2406.19852](https://doi.org/10.48550/arXiv.2406.19852).
- [4] Ding Ding and H. Howie Huang. A graph attention based approach for trajectory prediction in multi-agent sports games. *arXiv preprint arXiv:2012.10531*, 2020. doi:[10.48550/arXiv.2012.10531](https://doi.org/10.48550/arXiv.2012.10531).
- [5] Agrim Gupta, Justin Johnson, Li Fei-Fei, Silvio Savarese, and Alexandre Alahi. Social gan: Socially acceptable trajectories with generative adversarial networks. In *2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 2255–2264, 2018. doi:[10.1109/CVPR.2018.00240](https://doi.org/10.1109/CVPR.2018.00240).
- [6] David K. Hammond, Pierre Vandergheynst, and Rémi Gribonval. Wavelets on graphs via spectral graph theory. *Applied and Computational Harmonic Analysis*, 30(2):129–150, 2011. doi:[10.1016/j.acha.2010.04.005](https://doi.org/10.1016/j.acha.2010.04.005).
- [7] Tim Salzmann, Boris Ivanovic, Punarjay Chakravarty, and Marco Pavone. Trajectron++: Dynamically-feasible trajectory forecasting with heterogeneous data. In *Computer Vision – ECCV 2020*, pages 683–700. Springer, 2020. doi:[10.1007/978-3-030-58523-5_40](https://doi.org/10.1007/978-3-030-58523-5_40).
- [8] Michael Schlichtkrull, Thomas N. Kipf, Peter Bloem, Rianne van den Berg, Ivan Titov, and Max Welling. Modeling relational data with graph convolutional networks. In *The Semantic Web*, pages 593–607. Springer, 2018. doi:[10.1007/978-3-319-93417-4_38](https://doi.org/10.1007/978-3-319-93417-4_38).
- [9] SkillCorner. Open data: Football tracking and event data. <https://github.com/SkillCorner/opendata>. Conjunt de dades de deu partits de l’A-League 2024/2025. Consulta: 12 de juny de 2026.
- [10] Georgy Voronoi. Nouvelles applications des paramètres continus à la théorie des formes quadratiques. deuxième mémoire. recherches sur les paralléloèdres primitifs. *Journal für die reine und angewandte Mathematik*, 134:198–287, 1908. doi:[10.1515/crll.1908.134.198](https://doi.org/10.1515/crll.1908.134.198).
- [11] Zhe Wang, Petar Veličković, Daniel Hennes, Nenad Tomašev, et al. Tacticalai: An ai assistant for football tactics. *Nature Communications*, 15(1):1906, 2024. doi:[10.1038/s41467-024-45965-x](https://doi.org/10.1038/s41467-024-45965-x).
- [12] Bing Yu, Haoteng Yin, and Zhanxing Zhu. Spatio-temporal graph convolutional networks: A deep learning framework for traffic forecasting. In *Proceedings of the Twenty-Seventh International Joint Conference on Artificial Intelligence*, pages 3634–3640, 2018. doi:[10.24963/ijcai.2018/505](https://doi.org/10.24963/ijcai.2018/505).

A Preprocessament de les dades per STGCN

En aquesta secció es descriu el procés de transformació de les dades originals en una representació adequada per al model proposat. En particular, es detallen les decisions preses per representar el partit com un sistema multiagent en forma de graf.

Cada instant del joc es representa com un graf amb $N = 23$ nodes, on N denota sempre el nombre de nodes del graf. Aquests nodes es reparteixen en 11 jugadors de l'equip local, 11 de l'equip visitant i la pilota. Cada node ocupa sempre la mateixa posició del vector de nodes —una ranura—, de manera que la ranura i designa sempre el mateix agent al llarg de tota la finestra temporal:



Aquesta mida fixa respon a una necessitat de l'arquitectura. Les dades de seguiment provenen de les emissions dels partits i el nombre de jugadors detectats pot variar d'un frame a l'altre per culpa de jugadors fora de l'enquadrament i entrades i sortides del camp. La solució proposada, en canvi, necessita un conjunt de nodes constant i amb identitat estable i això només té sentit si la ranura i es refereix al mateix jugador a tots els fotogrames de la finestra. Per això fixem el nombre de nodes a 23 i, abans de construir el graf, resollem quins jugadors reals ocupen cada ranura.

Per assignar les ranures, per a cada partit i cada part comptem en quants fotogrames apareix detectat cada jugador i en retenim els 11 amb més presència de cada equip per separat, ordenats internament pel seu identificador per garantir un ordre determinista entre execucions. Fer aquesta selecció per equip, i no sobre el conjunt global de jugadors és imprescindible per garantir una representació equilibrada d'exactament 11 nodes per equip.

La representació de mida fixa té, això sí, una limitació en el cas de les substitucions. Un suplent que entra a meitat de part hereta una ranura només si la seva presència supera la d'algun dels titulars del seu equip; si entra molt tard, pot quedar fora i no ser representat al graf, i els fotogrames en què ell era realment al camp queden assignats al jugador que va substituir, ja absent. És un soroll inevitable amb una representació de nodes fixa.

Un cop fixades les identitats dels nodes, cada part del partit queda representada com una seqüència contínua de fotogrames amb les posicions de tots els nodes. D'aquesta seqüència n'extraïem les mostres d'entrenament mitjançant una finestra lliscant de longitud $N_{\text{frame}} = 80$ fotogrames que es desplaça amb un pas regular de $s = 5$ fotogrames. Cada posició de la finestra que supera la política de rebuig que s'esmenta més abaix, es desa com una mostra independent: un fragment de 80 fotogrames consecutius amb les coordenades (x, y) dels 23 nodes, sobre el qual ja no es conserva cap referència a quin partit o instant del partit prové. Cada mostra es divideix en dues parts:

- Els primers $N_{\text{HIS}}^{10} = 50$ fotogrames (5 s) constitueixen l'historial d'entrada;
- Els últims $N_{\text{PRED}}^{11} = 30$ fotogrames (3 s) són l'horitzó a predir.

Cada finestra de 80 fotogrames passa tres comprovacions abans de ser acceptada al conjunt de dades:

1. La pilota no pot faltar mai: si en algun frame de la finestra no se'n coneix la posició, la finestra es rebutja sense interpolar res. La pilota és el centre semàntic del joc i, sense la

¹⁰Nombre de fotogrames d'historial que rep el model com a entrada, fixat a 50 (5 segons a 10 fotogrames per segon) .

¹¹Nombre de fotogrames futurs que el model ha de predir, fixat a 30 (3 segons a 10 fotogrames per segon).

seva posició real durant la història d'entrada, els jugadors perden la referència principal sobre la qual articulen el moviment; interpolari-la introduiria artefactes amplificats per la incertesa de la predicció a tres segons vista.

2. Es distingeix entre una ranura inactiva i una observació perduda. Com que la representació reserva una posició fixa per a cada possible jugador, una ranura amb totes dues coordenades iguals a zero durant tota la finestra indica que aquell jugador no hi participa. Aquesta absència estructural no s'ha d'interpretar com una successió de dades mancants. Si $\mathcal{A}$ denota el conjunt de nodes actius, $p_{t,n,c}$ representa la coordenada $c \in \{x, y\}$ del node n al fotograma t , i $\mathcal{M}$ és el conjunt d'observacions que no estan disponibles, la proporció de valors mancants es calcula com

$$r_{\text{mancants}} = \frac{\sum_{n \in \mathcal{A}} \sum_{t=1}^T \sum_{c \in \{x,y\}} \mathbb{I}[(t, n, c) \in \mathcal{M}]}{2T|\mathcal{A}|},$$

on T és el nombre de fotogrames de la finestra i $\mathbb{I}[\cdot]$ és la funció indicadora, definida com

$$\mathbb{I}[(t, n, c) \in \mathcal{M}] = \begin{cases} 1, & (t, n, c) \in \mathcal{M}, \\ 0, & (t, n, c) \notin \mathcal{M}. \end{cases}$$

Per tant, aquesta funció aporta una unitat al numerador quan falta una coordenada concreta i no hi aporta res quan l'observació està disponible. La suma compta així el nombre total de coordenades no observades entre els nodes actius. La finestra només s'accepta si aquesta proporció no supera el 20%¹². Per exemple, si quatre de les 23 ranures estan inactives, el càlcul es fa sobre els 19 nodes que realment contenen observacions. Incloure les ranures inactives en el denominador, però no en el numerador, reduiria artificialment la proporció obtinguda i faria el criteri d'acceptació més permissiu precisament en les finestres amb menys jugadors presents.

3. Un cop superada aquesta validació, els valors mancants puntuals dels nodes actius es reconstrueixen per separat per a cada coordenada mitjançant interpolació lineal. Si t_a i t_b són els fotogrames vàlids immediatament anterior i posterior a un buit, el valor d'un instant intermedi t s'estima com

$$\hat{p}_{t,n,c} = p_{t_a,n,c} + \frac{t - t_a}{t_b - t_a} (p_{t_b,n,c} - p_{t_a,n,c}), \quad t_a < t < t_b.$$

Aquesta operació equival a assumir un desplaçament uniforme durant un interval breu i conserva exactament les observacions situades als seus extrems. Quan el buit apareix al principi o al final de la finestra, es manté la primera o l'última posició coneguda, respectivament, per evitar extrapolar un moviment del qual no es disposa d'informació. Es va descartar l'alternativa d'omplir els buits amb zeros ja que l'origen de coordenades se situa al centre del camp. Així doncs, aquesta opció representaria un desplaçament instantani cap al centre i generaria, entre d'altres problemes, velocitats artificials i físicament impossibles.

A.1 Normalització

Sobre el conjunt d'entrenament i només sobre ell, es calcula la mitjana i la desviació estàndard de les dues coordenades:

$$\mu_x \approx -0,22, \quad \mu_y \approx -1,16, \quad \sigma_x \approx 19,89, \quad \sigma_y \approx 12,83.$$

¹²Proporció màxima de valors mancants tolerada en una finestra.

Les mitjanes són aproximadament zero a causa de la simetria del camp i de la dinàmica del joc, ja que el centre del terreny de joc acostuma a ser una de les zones amb més aflluència de jugadors. A més, aquest resultat també es pot explicar pel fet que els esquemes tàctics dels equips tendeixen a repartir els jugadors de manera homogènia entre les diferents zones del camp. Per altra banda, les desviacions reflecteixen les mides físiques del camp, 105×68 m. Cada coordenada es normalitza amb z-score:

$$\hat{x}_{i,c} = \frac{x_{i,c} - \mu_c}{\sigma_c}, \quad c \in \{x, y\}.$$

La parella (μ, σ) es guarda i s'utilitza per desnormalitzar les sortides del model a l'hora d'avaluar. D'aquesta manera, totes les mètriques de trajectòria es donen i es comparen en metres físics i no en unitats normalitzades.

A.2 Partició de dades

La partició es realitza per partit i no per seqüència. Aquesta decisió és especialment important perquè les mostres s'obtenen mitjançant una finestra lliscant de 80 fotogrames amb un desplaçament de només 5. En conseqüència, dues finestres consecutives comparteixen 75 fotogrames, és a dir, un 93,75% del seu contingut. Si les seqüències es repartissin aleatòriament, els conjunts d'entrenament i d'avaluació podrien contenir fragments gairebé idèntics d'una mateixa jugada. El model seria avaluat, per tant, sobre situacions que ja hauria observat parcialment durant l'entrenament, fet que provocaria una fuga d'informació¹³.

La partició de les dades, limitada per la poca quantitat de partits disponibles, ha estat la següent:

Conjunt	Partits	Seqüències	Forma
Entrenament	8	61.077	(61077, 80, 23, 2)
Validació	1	8.729	(8729, 80, 23, 2)
Test	1	6.913	(6913, 80, 23, 2)

Taula 6: Distribució dels partits i les seqüències entre els conjunts d'entrenament, validació i test. La columna "Forma" indica les dimensions dels tensors de trajectòries associats a cada partició.

B Preprocessament de les dades pel model amb graf relacional: la fase com a unitat de mostra

L'estratègia de mostreig del model amb horitzó variable se separa de la formulació STGCN en dos aspectes essencials: la unitat de mostra és la fase de joc en lloc d'una finestra de longitud fixa, i l'instant de predicció t dins d'una mostra es tria de manera diferent segons si la mostra alimenta entrenament o avaluació. A continuació es detallen els procediments seguits.

B.1 Construcció i mostreig per fases

Per començar, cada element del conjunt de dades es construeix al voltant d'una fase de joc del partit. L'índex global de mostres és el conjunt de tripletes:

$$(\text{partit}, \text{fase}, \text{rèplica temporal}).$$

¹³En aquest context, una fuga d'informació es produeix quan el conjunt d'entrenament i el conjunt de validació o test contenen mostres massa relacionades entre si. Això pot fer que el model sigui avaluat sobre situacions molt semblants a les que ja ha vist durant l'entrenament i, per tant, pot donar lloc a una estimació massa optimista del seu rendiment

El primer component identifica el partit, el segon la fase actual dins del fitxer de fases i el tercer indica quina rèplica temporal (més tard s'entrarà en detall sobre aquest concepte) s'està construint.

Podem notar, aleshores, que una mateixa fase pot donar lloc a diferents instants de predicció segons si la mostra pertany a entrenament o a validació, i aquest instant no cal fixar-lo abans de cada època. Més tard, en l'apartat B.2 es detallarà quin és el sentit d'aquest fet.

Aquesta organització és estructuralment diferent de la finestra lliscant emprada pel model STGCN. En aquella formulació, dues mostres consecutives compartien 75 dels seus 80 fotogrames i la mida del conjunt de dades depenia del pas de la finestra.

Per altra banda, no totes les fases poden convertir-se en una mostra supervisada. Es considera vàlida una fase i si compleix dues condicions:

1. Existeix una fase $i + 1$ posterior dins del mateix període;
2. El tipus de fase de l'equip en possessió a la fase actual està definit.

La primera condició evita construir transicions entre la primera i la segona part del partit. La segona evita entrenar el model sobre una entrada que no té interpretació tàctica clara.

B.2 Selecció de l'instant de predicció i augmentació estocàstica

Per a una fase actual amb fotograma inicial f_{start} i fotograma final f_{end} , l'instant de predicció t es tria dins de la fase. El límit inferior no coincideix exactament amb l'inici de la fase, sinó amb el primer instant que garanteix una observació mínima:

$$t_{\min} = f_{\text{start}} + (m_{\min} - 1)s, \quad t_{\max} = f_{\text{end}} - 1.$$

En la configuració actual $m_{\min} = 2$ i el pas temporal és $s = 3$ fotogrames. Així, la fase actual aporta com a mínim dos fotogrames mostrejats. Aquesta restricció evita mostres on el model hauria de predir sense tenir context de la fase actual.

Durant l'entrenament, l'instant t es mostreja de manera aleatòria i uniforme dins del rang admissible. Si només es genera una mostra per fase, es pren:

$$t \sim \mathcal{U}([t_{\min}, t_{\max}])^{14}.$$

Quan es volen obtenir diverses rèpliques temporals d'una mateixa fase, el rang es divideix en M segments i cada rèplica mostreja dins del seu segment:

$$[t_{\min}, t_{\max}] = I_1 \cup I_2 \cup \dots \cup I_M, \quad t_m \sim \mathcal{U}(I_m),$$

per a $m = 1, \dots, M$. Aquest mostreig estratificat incrementa en M vegades el nombre de mostres efectives que el model veu durant l'entrenament. A més, redueix el risc que el model aprengui només a predir transicions des d'instants molt propers al final. S'ha treballat amb $M = 3$ ja que s'ha considerat que ofereix el balanç idoni entre l'augmentació de les dades i la no correlació entre les mostres d'una mateixa fase.

En validació i prova s'evita l'aleatorietat. Cada fase s'avalua en tres punts deterministes, situats al 25%, 50% i 75% del rang admissible. Per a cada fracció $\alpha \in \{0.25, 0.50, 0.75\}$, l'instant és

$$t(\alpha) = t_{\min} + \lfloor \alpha (t_{\max} - t_{\min}) \rfloor.$$

¹⁴La notació $\mathcal{U}([a, b])$ representa una distribució uniforme discreta, on cada valor enter entre a i b té la mateixa probabilitat de ser seleccionat.

Avaluar cada fase en tres punts redueix el biaix d'una validació feta només prop del final de la fase.

La finestra d'observació que rep l'encoder és l'interval temporal del partit a partir del qual el model ha d'inferir la transició cap a la propera fase de joc partint de l'instant t . La primera decisió a prendre és quant context li donem al model, és a dir; fins on enrere mirem respecte el fotograma de predicció t .

Una primera opció seria limitar-se a la fase actual: el tram del joc que s'està desenvolupant en aquell moment, des del seu inici fins a l'instant de predicció t . Aquesta opció, però, ignora una propietat important del joc: una fase d'un partit de futbol està condicionada per la fase que la precedeix, com bé s'ha comentat a l'assumpció 4 de l'apartat 4.2.1. Per aquest motiu, la finestra també incorpora la fase immediatament anterior, sempre que pertanyi al mateix període. La condició és necessària perquè entre períodes el joc s'atura i els equips canvien de camp.

Formalment, denotem per $f_{\text{start}}^{\text{prev}}$ i $f_{\text{start}}^{\text{curr}}$ els fotogrames d'inici de la fase prèvia i de la fase actual, respectivament. El primer fotograma de la finestra es defineix com

$$f_0 = \begin{cases} f_{\text{start}}^{\text{prev}}, & \text{si hi ha fase prèvia al mateix període,} \\ f_{\text{start}}^{\text{curr}}, & \text{altrament.} \end{cases}$$

Tenint en compte que es conserva un fotograma de cada s consecutius, amb pas $s = 3$. El conjunt de fotogrames observats és, doncs:

$$\mathcal{T}_{\text{obs}} = \{f_0, f_0 + s, f_0 + 2s, \dots, t\}, \quad s = 3,$$

És a dir el conjunt de fotogrames amb límit inferior f_0 i amb l'instant t mostrejat aleatòriament com a límit superior.

Per altra banda, la durada conjunta de la fase prèvia i de la fase actual és variable, i per mantenir totes les mostres dins d'una mida comparable la finestra es limita a un màxim de $T_{\text{max}} = 100$ fotogrames mostrejats. Com que el senyal original té una freqüència de 10 fotogrames per segon i es pren un fotograma de cada tres, aquesta longitud equival a 30s. Si $|\mathcal{T}_{\text{obs}}| > T_{\text{max}}$, es descarten els fotogrames més antics:

$$\mathcal{T}_{\text{obs}} \leftarrow \mathcal{T}_{\text{obs}}[-T_{\text{max}} :].$$

La decisió de retallar pel principi i no pel final és coherent amb l'objectiu del model: l'instant t i la fase actual són la base de la predicció, i la informació es torna progressivament menys rellevant cap al passat.

C Visualitzacions complementàries dels procediments

Aquest annex recull figures que il·lustren alguns dels procediments seguits al llarg del treball i que, per claredat, no s'han inclòs al cos principal.

C.1 Control d'espai: Voronoi versus regió dominant




Figura 8: Comparació de les dues estratègies de control d'espai per equip sobre una mateixa instantània (mostra 600 del partit de validació). A l'esquerra, el *nivell 0* assigna cada punt del camp a l'equip del jugador més proper segons la distància euclidiana (tessel·lació de Voronoi); a la dreta, el *nivell 1* (regió dominant) és la versió descrita al treball que incorpora les velocitats dels jugadors i assumeix que hi ha un temps de reacció.

C.2 Estructura de les relacions tàctiques del graf multi-relacional



Figura 9: Seqüència temporal del graf multi-relacional al llarg d'una mateixa jugada (fase de tipus *finish*, de 5 segons de durada, amb atac de dreta a esquerra). Cada subgràfic correspon a una instantània del camp en un instant successiu on es representen els jugadors dels dos equips i les arestes que codifiquen les relacions tàctiques entre ells: opcions de passada (*passing option*), desmarcades (*off-ball run*), pressió sobre el posseïdor (*on-ball engagement*) i possessió de la pilota. La figura permet visualitzar com, a mesura que la jugada avança, les línies de passada i de desmarcada augmenten quan els atacants obren noves línies cercant espais lliures i disminueixen quan els defensors els tanquen.

C.3 Corbes d'aprenentatge




Figura 10: Evolució de la funció de pèrdua i de la mètrica FDE en entrenament i validació per als models STGCN estàtic i dinàmic.




Figura 11: Corbes d'entrenament i validació del model multi-head amb cap de trajectòria probabilístic. Es mostren l'evolució de l'error de trajectòria, l'error final, la pèrdua NLL de trajectòria, l'accuracy de la classificació d'event, l'accuracy del canvi de possessió i la pèrdua total al llarg de les èpoques. La línia vertical discontinua indica l'època amb millor rendiment de validació.

C.4 Exemples qualitatius de predicció de trajectòries




Figura 12: Validació qualitativa dels models STGCN estàtic i dinàmic sobre tres seqüències del conjunt de prova. Per a cada seqüència es mostren les trajectòries reals i les trajectòries predites dels jugadors i de la pilota durant l'horitzó de tres segons.




Figura 13: Exemples qualitatius addicionals de tres prediccions de transició de fase del conjunt de test. Cada fila correspon a una fase diferent i compara la trajectòria real fins a l'inici de la fase següent amb la predicció del cap determinista entrenat amb MSE i del cap probabilístic entrenat amb NLL.

D Repositori del codi

El codi font utilitzat per al desenvolupament, entrenament i avaluació dels models presentats en aquest treball es troba disponible al següent repositori:

https://github.com/NIU1666675/stgcn_football_tracking

El repositori s'organitza principalment en dos directoris: `stgcn_tracking/`, corresponent al bloc STGCN, i `multi_head_model/`, corresponent al model de múltiples capçaleres. També inclou el quadern `exploratory_data.ipynb`, utilitzat per al preprocessament i l'anàlisi exploratòria inicial. El desenvolupament s'ha organitzat en sis branques; la branca `voronoi` conté els canvis més recents i la versió final utilitzada per tancar el treball. Cal tenir en compte que GitHub no permet pujar fitxers de més de 20 MB, motiu pel qual el repositori no inclou ni les dades originals ni les figures generades durant els experiments.

Els fitxers principals són els següents:

1. `stgcn_tracking/Dataset.py`: carrega les seqüències de seguiment i construeix les variants d'entrada del model STGCN, incloent les característiques augmentades.
2. `stgcn_tracking/layers.py`: defineix les capes bàsiques de el model STGCN, com les convolucions temporals amb porta i la convolució espectral sobre el graf.
3. `stgcn_tracking/model.py`: implementa les arquitectures STGCN estàtica i dinàmica.
4. `stgcn_tracking/train.py`: executa l'entrenament, la validació i la prova dels models amb horitzó fix. Està preparat per rebre diferents configuracions des de terminal, com ara l'ús del graf dinàmic, el conjunt de característiques d'entrada, el nombre d'èpoques, la mida del lot o la taxa d'aprenentatge.
5. `stgcn_tracking/visualize.py`: genera visualitzacions qualitatives de les trajectòries predites.
6. `multi_head_model/dataset.py`: construeix les mostres basades en fases, el graf relacional i les etiquetes supervisades del model multi-head.
7. `multi_head_model/encoder.py`: implementa el codificador espai-temporal, format per capes relacionals sobre grafs i un transformador temporal.
8. `multi_head_model/heads.py`: defineix les capçaleres de fase, pausa, canvi de possessió i trajectòria.
9. `multi_head_model/losses.py`: agrupa les funcions de pèrdua utilitzades per entrenar conjuntament les diferents capçaleres.
10. `multi_head_model/model.py`: integra el codificador i les capçaleres en el model complet.
11. `multi_head_model/train.py`: entrena el model multi-head i desa els registres i pesos del millor model. També funciona com a script configurable des de terminal, amb paràmetres com el tipus d'agregació global, l'activació del control d'espai, el nombre de mostres per fase, els pesos de classe, el nombre d'èpoques, la mida del lot o la taxa d'aprenentatge.
12. `multi_head_model/validate.py`: calcula mètriques i anàlisis de validació sobre la representació apresada i les sortides del model.
13. `multi_head_model/spatial_control.py`: calcula les característiques de control d'espai basades en Voronoi.

14. `multi_head_model/precompute_spatial_control.py`: precalcula i desa a disc les característiques de control d'espai per fer més eficient l'entrenament.

Els fitxers de configuració de cada bloc, com `constants.py`, recullen les dimensions del problema, els paràmetres de mostreig i els hiperparàmetres per defecte. Aquesta separació permet reproduir els experiments principals i, alhora, modificar de manera controlada aspectes com la longitud de les finestres, el nombre de mostres per fase o les característiques d'entrada.